

Комп'ютерного практикуму №1

з дисципліни

«Криптографія»

«Експериментальна оцінка ентропії на символ джерела відкритого тексту»

Виконали:
студенти групи ФБ-42 Кочаров Д.
та Тіньков Д.

Перевірів(ла): Селюх Поліна Валентинівна

2026

1. Мета роботи

Засвоїти поняття ентропії на символ джерела та його надлишковості, дослідити різні моделі джерела відкритого тексту, експериментально оцінити ентропію природного російськомовного тексту та порівняти оцінки, отримані за статистикою окремих символів, біграм і довшого контексту.

2. Короткі теоретичні відомості

Ентропія характеризує середню невизначеність випадкового джерела. Для ансамблю символів із ймовірностями p_i ентропія обчислюється за формулою:

$$H = -\sum p_i \log_2 p_i.$$

Для моделі незалежних символів використовується H_1 . Для біграм спочатку обчислюється ентропія розподілу пар символів, після чого вона ділиться на 2, оскільки одна біграма містить два символи:

$$H_2 = -(1/2) \sum p_{ij} \log_2 p_{ij}.$$

Максимальна ентропія для рівноймовірного алфавіту з m символів дорівнює $H_0 = \log_2(m)$. Надлишковість джерела визначається як:

$$R = 1 - H/H_0.$$

3. Вихідні дані та попередня обробка

Як відкритий текст використано російськомовний роман Ф. М. Достоевського «Братья Карамазовы». Розмір вихідного файлу становить 1 834 218 байт, тобто перевищує вимогу 1 МБ. Файл зчитувався у кодуванні Windows-1251 (cp1251).

У скрипті 1.py реалізовано такі правила нормалізації: усі літери переводяться у нижній регістр; літера «ё» замінюється на «е»; символи поза російським алфавітом перетворюються на пробіл; послідовності пробілів зводяться до одного; для варіанта без пробілів усі пробіли вилучаються. Використовується алфавіт із 32 літер без «ё»; з урахуванням пробілу алфавіт містить 33 символи.

```

PS E:\VS code\Microsoft VS Code> & C:\Users\daniil\AppData\Local\Python\pythoncore-3.14-64\python.exe e:/Crypto/1.py
Вихідний файл: e:\Crypto\bratia_karamazovy.txt
Довжина сирого тексту: 1821802
Довжина після нормалізації (з пробілами): 1719594
Довжина без пробілів: 1422571
Перші 300 символів після обробки:
самий складний і неоднозначний з романів Достоєвського, який критики считали то інтелектуальним детективом, то раннім постмодернізмом, то кращим із произведений о загадочной русск
й душе роман, легший в основу десятков экранизаций от предельно точных до самых отвлеченных, но не уг

```

Показник	Значення
Довжина сирого тексту	1 821 802 символи
Після нормалізації з пробілами	1 719 594 символи
Після вилучення пробілів	1 422 571 символ
Алфавіт без пробілу	32 символи
Алфавіт із пробілом	33 символи

4. Програмна реалізація

Роботу поділено на п'ять файлів. Скрипт 1.py виконує нормалізацію тексту та створює два підготовлені файли. Скрипт 2.py підраховує частоти символів і біграм, обчислює H_1 та H_2 для перетинних і неперетинних біграм, визначає топ-5 елементів і надлишковість. Скрипт 3.py реалізує експеримент А-Б-В, скрипт 4.py - експеримент Г-Д. Файл common.py містить спільні функції підрахунку частот, ентропії, H_1 , H_2 і надлишковості.

Перевірка коду показала, що формули реалізовані коректно. Зокрема, у H_2 ентропія ансамблю біграм ділиться на 2, що відповідає питомій ентропії на один символ. Перетинні біграми формуються зі зсувом 1, неперетинні - зі зсувом 2. Єдина практична особливість: у скриптах 3.py та 4.py генератор випадкових чисел не має фіксованого seed, тому при повторному запуску випадкові послідовності можуть дещо відрізнятися; це не впливає на коректність експерименту.

5. Статистичні характеристики природного тексту

5.1. Частоти символів

ТОП-5 символів:

'_ ' 297,023 p = 0.172729
'o' 162,009 p = 0.094214
'e' 126,830 p = 0.073756
'a' 109,637 p = 0.063757
'и' 96,289 p = 0.055995

Символ	Кількість	Частота
—	297 023	0.172729
o	162 009	0.094214
e	126 830	0.073756
a	109 637	0.063757
и	96 289	0.055995
т	93 717	0.054499
н	87 517	0.050894
с	75 368	0.043829
в	66 264	0.038535
л	64 161	0.037312
р	57 810	0.033618
м	47 396	0.027562
к	46 444	0.027009
д	45 176	0.026271
у	41 234	0.023979
п	37 816	0.021991
я	29 460	0.017132
ь	29 427	0.017113
г	27 432	0.015953
б	25 771	0.014987
ч	25 563	0.014866
ы	23 904	0.013901
з	21 866	0.012716
ж	15 857	0.009221
й	14 347	0.008343
ш	13 784	0.008016
х	10 948	0.006367
ю	9 720	0.005652

Символ	Кількість	Частота
э	5 168	0.003005
ц	4 824	0.002805
щ	4 066	0.002365
ф	2 428	0.001412
ъ	338	0.000197

П'ять найчастіших символів у тексті з пробілами: пробіл (0,172729), «о» (0,094214), «е» (0,073756), «а» (0,063757) та «и» (0,055995). Висока частота пробілу є очікуваною для природного тексту й суттєво впливає на розподіл біграм.

5.2. Ентропія H_1 та H_2

варіант	H_1	H_2 перет.	H_2 неперет.
з пробілами	4.3544	3.9432	3.9429
без пробілів	4.4611	4.1412	4.1409

Варіант	H_0	H_1	H_2 перет.	H_2 неперет.	$R(H_1)$	$R(H_2 \text{ перет.})$
З пробілами	5.0444	4.3544	3.9432	3.9429	0.1368	0.2183
Без пробілів	5.0000	4.4611	4.1412	4.1409	0.1078	0.1718

Для тексту з пробілами $H_1 = 4,3544$ біт/символ, а H_2 для перетинних біграм зменшується до 3,9432 біт/символ. Це означає, що врахування залежностей між сусідніми символами зменшує невизначеність. Для тексту без пробілів $H_1 = 4,4611$, а $H_2 = 4,1412$ біт/символ. Отже, вилучення пробілів у цьому експерименті збільшило обидві оцінки ентропії.

Результати для перетинних і неперетинних біграм майже збігаються: 3,9432 проти 3,9429 біт/символ із пробілами та 4,1412 проти 4,1409 без пробілів. Причина близькості - великий обсяг тексту. Перетинний спосіб використовує приблизно вдвічі більше біграм, тому спирається на більший обсяг статистичних даних.

5.3. Найчастіші біграми

Текст з пробілами, біграми перетинні:

Біграма	Кількість	Частота
о_	42 886	0.024940
е_	33 590	0.019534
и_	31 305	0.018205
_в	29 024	0.016878
_с	28 055	0.016315
а_	27 753	0.016139
_н	27 747	0.016136
_п	26 629	0.015486
то	25 011	0.014545
_и	21 548	0.012531

Текст з пробілами, біграми неперетинні:

Біграма	Кількість	Частота
о_	21 436	0.024931
е_	16 798	0.019537
и_	15 451	0.017971
_в	14 731	0.017133
_с	14 111	0.016412
_н	13 962	0.016239
а_	13 835	0.016091
_п	13 286	0.015452
то	12 548	0.014594
_и	10 942	0.012726

Текст без пробілів, біграми перетинні:

ТОП-5 біграм:		
'то'	25,690	p = 0.018059
'не'	17,767	p = 0.012489
'ов'	17,171	p = 0.012070
'ст'	17,102	p = 0.012022
'но'	16,802	p = 0.011811

Біграма	Кількість	Частота
то	25 690	0.018059
не	17 767	0.012489

Біграма	Кількість	Частота
ов	17 171	0.012070
ст	17 102	0.012022
но	16 802	0.011811
на	15 621	0.010981
го	15 154	0.010653
по	14 649	0.010298
ен	14 512	0.010201
от	14 164	0.009957

Текст без пробілів, біграми неперетинні:

ТОП-5 біграм:

```
'то'      12,702  p = 0.017858
'не'      8,913   p = 0.012531
'ст'      8,583   p = 0.012067
'ов'      8,523   p = 0.011983
'но'      8,380   p = 0.011781
```

Біграма	Кількість	Частота
то	12 702	0.017858
не	8 913	0.012531
ст	8 583	0.012067
ов	8 523	0.011983
но	8 380	0.011781
на	7 893	0.011097
го	7 555	0.010622
по	7 342	0.010322
ен	7 284	0.010241
от	7 218	0.010148

У повному розподілі для тексту з пробілами спостерігається 761 різна перетинна біграма з 1089 можливих; без пробілів - 858 із 1024 можливих. У звіті наведено найчастотнішу частину таблиць, оскільки повний перелік містить сотні рядків і формується програмою автоматично.

6. Дослідження впливу розподілу символів на ентропію

Перед обчисленням очікувався порядок $B < A < V$: послідовність з одного повторюваного символу повинна мати нульову ентропію, природний текст - проміжну, а рівноймовірна випадкова послідовність - значення, близьке до максимуму $\log_2 32 = 5$ біт/символ.

```
Довжина кожної послідовності: 100000

А – фрагмент природного тексту:  H1 = 4.4576
Б – повторення одного символу:   H1 = 0.0000
В – рівноймовірна випадкова:     H1 = 4.9998
```

Послідовність	Опис	H ₁ , біт/символ
А	Фрагмент природного тексту	4.4576
Б	100 000 повторень символу «а»	0.0000
В	100 000 рівноймовірних випадкових символів	4.9998

Прогноз підтвердився: $0,0000 < 4,4576 < 4,9998$. Рівноймовірний розподіл створює максимальну невизначеність, тоді як вироджений розподіл з одним символом не містить невизначеності. Природна мова займає проміжне положення через нерівномірність частот букв.

7. Дослідження залежностей між символами

Для послідовностей Г і Д використано однаковий двосимвольний алфавіт та однакові кількості «а» і «б». До експерименту прогнозувалося, що H₁ буде однаковим, оскільки частоти окремих символів збігаються; H₂ має бути меншим для періодичної послідовності Д, оскільки вона значно передбачуваніша.

```
Довжина кожної послідовності: 100000

      H1  H2 перет.  H2 неперет.
Г      1.0000      1.0000      1.0000
Д      1.0000      0.5000      0.0000
```

Послідовність	H ₁	H ₂ перет.	H ₂ неперет.
Г - випадковий порядок	1.0000	1.0000	1.0000

Послідовність	H_1	H_2 перет.	H_2 неперет.
Д - «абабаб...»	1.0000	0.5000	0.0000

H_1 для обох послідовностей дорівнює 1 біт/символ, що підтверджує: H_1 не враховує порядок символів. Для випадкового Г H_2 залишається близьким до 1, а для періодичного Д зменшується до 0,5 для перетинних біграм і до 0 для неперетинних. Для «абабаб...» неперетинні біграми мають фактично один тип «аб», тому їхня ентропія дорівнює нулю.

8. Експериментальна оцінка ентропії в CoolPinkProgram

Для порядків 10, 20 і 30 символів виконано по 50 експериментів. CoolPinkProgram після 50-го експерименту виводить не одне число, а нерівність - нижню та верхню межі оцінки ентропії. Тому в таблиці наведено безпосередньо отримані інтервали. Для зручності порівняння додатково обчислено середину кожного інтервалу; вона є допоміжною точковою оцінкою, а не окремим результатом програми.

Оцінка	Інтервал CoolPinkProgram	Середина інтервалу
$H^{(10)}$	$2.2486 < H < 2.9813$	2.6150
$H^{(20)}$	$2.1568 < H < 2.8008$	2.4788
$H^{(30)}$	$2.3578 < H < 3.1815$	2.7697

[illegible]

Рисунок 1 - Результат CoolPinkProgram для порядку 10, эксперимент №50

[illegible]

Рисунок 2 - Результат CoolPinkProgram для порядку 20, експеримент №50




Рисунок 3 - Результат CoolPinkProgram для порядку 30, эксперимент №50

9. Порівняння оцінок ентропії

Оскільки у CoolPinkProgram використовується алфавіт із 32 варіантів $q[1]...q[32]$, для порівняння доцільно використовувати H_1 та H_2 тексту без пробілів. Для H_2 використано перетинні біграми, оскільки вони задіюють більше статистичних даних.

Оцінка	Отримане значення / інтервал	Модель
H_1	4.4611	частоти окремих символів
H_2	4.1412	частоти перетинних біграм
$H^{(10)}$	2.2486...2.9813	50 експериментів CoolPinkProgram; середина 2.6150
$H^{(20)}$	2.1568...2.8008	50 експериментів CoolPinkProgram; середина 2.4788
$H^{(30)}$	2.3578...3.1815	50 експериментів CoolPinkProgram; середина 2.7697

Спостерігається загальна тенденція до зменшення оцінки ентропії при врахуванні контексту: $H_1 > H_2$, а всі інтервали $H^{(10)}$, $H^{(20)}$ і $H^{(30)}$ лежать істотно

нижче H_2 . Значення для порядків 10, 20 і 30 не утворюють строго монотонної послідовності: середина інтервалу для 30 символів вища, ніж для 20. Це можна пояснити експериментальним характером методу, залежністю від дій людини, конкретних фрагментів тексту та обмеженою кількістю дослідів. Теоретично довший контекст не збільшує істинну умовну ентропію, але емпіричні оцінки можуть флюктувати.

10. Оцінювання надлишковості джерела

Для тексту без пробілів $H_0 = \log_2 32 = 5$ біт/символ. Надлишковість за моделлю окремих символів становить 0,1078, а за біграмною моделлю - 0,1718. Для оцінок CoolPinkProgram надлишковість також є інтервальною: якщо H належить $[H_{\min}; H_{\max}]$, то R належить $[1-H_{\max}/5; 1-H_{\min}/5]$.

Модель	R	У відсотках
H_1	0.1078	10,78 %
H_2	0.1718	17,18 %
$H^{(10)}$	0.4037...0.5503	40.37...55.03 %
$H^{(20)}$	0.4398...0.5686	43.98...56.86 %
$H^{(30)}$	0.3637...0.5284	36.37...52.84 %

Зі збільшенням обсягу врахованих залежностей оцінена ентропія в цілому зменшується, а надлишковість зростає. Це означає, що природна мова містить статистичні закономірності, які роблять наступний символ частково передбачуваним і створюють можливість стиснення без втрати інформації.

11. Аналіз результатів

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівномірна послідовність?

У природному тексті символи розподілені нерівномірно та пов'язані мовними закономірностями. У досліді А отримано $H_1 = 4.4576$, тоді як для

рівноймовірної випадкової послідовності В $H_1 = 4.9998$, тобто майже максимальні 5 біт/символ.

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

H_1 враховує лише частоти окремих символів, а H_2 - спільні частоти сусідніх пар. Для тексту без пробілів $H_1 = 4.4611$, тоді як $H_2 = 4.1412$; зменшення показує наявність залежностей між сусідніми буквами.

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ?

Так. У послідовностей Г і Д $H_1 = 1,0000$, оскільки частоти «а» і «б» однакові. Водночас H_2 для Г дорівнює 1,0000, а для періодичного Д - 0,5000 для перетинних і 0,0000 для неперетинних біграм.

4. Як вилучення пробілів вплинуло на отримані значення ентропії?

Після вилучення пробілів H_1 збільшилося з 4.3544 до 4.4611, а H_2 - з 3.9432 до 4.1412. Пробіл є дуже частим і добре структурованим символом, тому його наявність робить розподіл більш нерівномірним та підсилює передбачуваність пар символів.

5. Чому H_2 для перетинних і неперетинних біграм дещо відрізняється?

Способи використовують різні набори позицій. Перетинний варіант бере майже $N-1$ пар, неперетинний - приблизно $N/2$. На великому природному тексті значення майже збіглися, але у спеціально структурованій послідовності Д різниця стала принциповою: 0,5000 проти 0,0000.

6. Чому значення H_1 , H_2 , $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ відрізняються?

Ці оцінки використовують різний обсяг контексту. H_1 описує незалежні символи, H_2 - пари, а CoolPinkProgram використовує довший контекст. Чим більше закономірностей доступно для прогнозування, тим меншою є невизначеність наступного символу. Емпіричні $H^{(n)}$ додатково залежать від конкретних 50 дослідів і дій експериментатора.

7. Який експеримент найкраще демонструє залежності між послідовними символами?

Експеримент Г-Д, тому що частоти окремих символів у двох послідовностях однакові, але порядок різний. Незмінне H_1 та різке зменшення H_2 для періодичної Д безпосередньо показують, яку інформацію додає модель біграм.

8. Як результати пов'язані з можливістю стиснення природного тексту без втрати інформації?

Для тексту без пробілів надлишковість зростає від 10.78% за H_1 до 17.18% за H_2 , а довший контекст CoolPinkProgram дає ще нижчі оцінки ентропії. Чим більша надлишковість, тим більше статистичних закономірностей можна використати під час ефективного кодування та стиснення.

12. Висновки

У роботі було виконано попередню обробку російськомовного тексту обсягом понад 1 МБ, визначено частоти символів і біграм, обчислено H_1 та H_2 для тексту з пробілами й без пробілів, а також для перетинних і неперетинних біграм. Для природного тексту врахування біграм зменшило оцінку ентропії, що підтверджує залежність між сусідніми символами.

Експеримент А-Б-В підтвердив зв'язок ентропії з характером розподілу ймовірностей: вироджена послідовність має $H_1 = 0$, природний текст - проміжне значення, а рівноймовірна випадкова послідовність - майже максимальне. Експеримент Г-Д показав, що однакові частоти символів не гарантують однакової ентропії біграм і що H_2 виявляє структурні залежності, невидимі для H_1 .

За CoolPinkProgram отримано інтервальні оцінки $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ після 50 експериментів для кожного порядку. Вони істотно нижчі за H_1 та H_2 , що узгоджується з ідеєю зменшення невизначеності при використанні довшого контексту. Водночас емпіричні оцінки не є строго монотонними через статистичну похибку та участь людини в експерименті. Отримані результати також демонструють ненульову надлишковість природної мови та її зв'язок із можливістю стиснення тексту.