

**МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
імені ІГОРЯ СІКОРСЬКОГО**

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ

КРИПТОГРАФІЯ

КОМП'ЮТЕРНИЙ ПРАКТИКУМ №1

Експериментальна оцінка ентропії на символ джерела відкритого тексту

**Виконали: Журавський Владислав
та Артем Валюх Група ФБ-43**

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Порядок виконання роботи

1. Підготовка тексту

Оберіть довільний текст російською мовою обсягом не менше 1 МБ.

Виконайте попередню обробку тексту відповідно до таких правил:

- усі літери привести до нижнього регістру;
- символи, що не належать до заданого алфавіту, вилучити або замінити пробілами;
- послідовності пробілів та інших розділових символів трактувати як один пробіл;
- для обчислень без пробілів вилучити всі пробіли з попередньо нормалізованого тексту.

Зафіксуйте правила попередньої обробки, використані у вашій програмі.

 Fxodor Dostoevski - - . Idiot - 52250.fb2	24.09.2026 0:15	Файл FB2	2 409 КБ
---	-----------------	----------	----------

Було обрано твір Ідіот(перша частина) Достоевського

Обробимо текст за допомогою скрипту `fb2_to_txt.py`:

```
PS C:\Users\Admin\AppData\Local\Programs\Microsoft VS Code> & C:\Users\Admin\AppData\Local\Microsoft\WindowsApps\python3.13.exe "c:\ukh\AI\fb2_to_txt.py"
Джерело: c:\Users\Admin\Desktop\Labs crypto\crypto26-27\lab1\FB43_Zhuravslji_Valiukh\AI\Fxodor Dostoevski - - . Idiot - 52250.fb2
Створено файл: russian_text_normalized.txt
Кількість символів після нормалізації: 1240274
Розмір: 2275829 байт

Створено файл: russian_text_no_spaces.txt
Кількість символів без пробілів: 1035555
Розмір: 2071110 байт

Правила попередньої обробки:
1. Усі літери переведено у нижній регістр.
2. Залишено тільки літери російського алфавіту.
3. Інші символи замінено пробілами.
4. Послідовності пробілів замінено одним пробілом.
5. Абзаци збережено окремо.
6. Для обчислень без пробілів створено окремий файл без пробілів.
PS C:\Users\Admin\AppData\Local\Programs\Microsoft VS Code>
```

2. Розрахунок статистичних характеристик тексту

Реалізуйте програму для:

1. підрахунку частот окремих символів;
2. підрахунку частот біграм;
3. обчислення H_1 за частотами окремих символів;
4. обчислення H_2 за частотами біграм.

Частоти біграм та відповідне значення H_2 визначте двома способами:

- для біграм, що перетинаються, тобто при послідовному зміщенні на один символ;
- для біграм, що не перетинаються, тобто при зміщенні на два символи.

Виконайте обчислення для:

- нормалізованого тексту з пробілом як символом алфавіту;
- того самого тексту після вилучення всіх пробілів.

Для кожного випадку визначте п'ять символів та п'ять біграм із найбільшими частотами.

Порівняйте значення H_2 , отримані для біграм, що перетинаються та не перетинаються.

Поясніть можливі відмінності між результатами та визначте, який спосіб використовує більше статистичних даних.

Пункт виконаний за допомогою скрипта lab1_2.py:

H_1 — обчислює ентропію окремих символів за формулою:

$$H_1 = -\sum p_i \cdot \log_2(p_i)$$

Для кожного символу визначається його ймовірність p_i як відношення частоти символу до загальної кількості символів у тексті. Потім ймовірність множиться на $\log_2(p_i)$, отримані значення сумуються та результат береться зі знаком «мінус».

H_2 — обчислює ентропію біграм за формулою:

$$H_2 = -(1/2) \cdot \sum p_{i\Box} \cdot \log_2(p_{i\Box})$$

Для кожної біграми визначається її ймовірність $p_{i\Box}$ як відношення частоти біграми до загальної кількості біграм. Потім обчислюється добуток $p_{i\Box} \cdot \log_2(p_{i\Box})$, усі отримані значення сумуються зі знаком «мінус» і результат ділиться на 2 для отримання ентропії на один символ. Розрахунок H_2 виконується окремо для пересічних та непересічних біграм.

```

=====
НОРМАЛІЗОВАНИЙ ТЕКСТ З ПРОБІЛАМИ
=====

Кількість символів: 1235803
Кількість пересічних біграм: 1235802
Кількість непересічних біграм: 617901

H1 = 4.36565885 біт/символ
H2 для пересічних біграм = 3.94449313 біт/символ
H2 для непересічних біграм = 3.94423221 біт/символ
Різниця між H2 = 0.00026092

5 символів з найбільшою частотою:
'[пробіл]' частота = 209190 ймовірність = 0.16927455
'o' частота = 115556 ймовірність = 0.09350681
'e' частота = 91584 ймовірність = 0.07410890
'a' частота = 81690 ймовірність = 0.06610277
'n' частота = 68838 ймовірність = 0.05570305

5 найбільш частих пересічних біграм:
'o ' частота = 31236 ймовірність = 0.02527589
'e ' частота = 23232 ймовірність = 0.01879913
'и ' частота = 21400 ймовірність = 0.01731669
'в ' частота = 20889 ймовірність = 0.01690319
'н ' частота = 20722 ймовірність = 0.01676806

5 найбільш частих непересічних біграм:
'o ' частота = 15731 ймовірність = 0.02545877
'e ' частота = 11715 ймовірність = 0.01895935
'и ' частота = 10713 ймовірність = 0.01733773
'в ' частота = 10472 ймовірність = 0.01694770
'н ' частота = 10380 ймовірність = 0.01679881

```

```

=====
НОРМАЛІЗОВАНИЙ ТЕКСТ БЕЗ ПРОБІЛІВ
=====

Кількість символів: 1026613
Кількість пересічних біграм: 1026612
Кількість непересічних біграм: 513306

H1 = 4.46551419 біт/символ
H2 для пересічних біграм = 4.13374992 біт/символ
H2 для непересічних біграм = 4.13429209 біт/символ
Різниця між H2 = 0.00054217

5 символів з найбільшою частотою:
'o' частота = 115556 ймовірність = 0.11256043
'e' частота = 91584 ймовірність = 0.08920986
'a' частота = 81690 ймовірність = 0.07957234
'n' частота = 68838 ймовірність = 0.06705351
'и' частота = 65520 ймовірність = 0.06382152

5 найбільш частих пересічних біграм:
'то' частота = 18227 ймовірність = 0.01775452
'не' частота = 13794 ймовірність = 0.01343643
'но' частота = 13069 ймовірність = 0.01273022
'на' частота = 12296 ймовірність = 0.01197726
'ст' частота = 12286 ймовірність = 0.01196752

5 найбільш частих непересічних біграм:
'то' частота = 9011 ймовірність = 0.01755483
'не' частота = 6930 ймовірність = 0.01350072
'но' частота = 6531 ймовірність = 0.01272340
'на' частота = 6078 ймовірність = 0.01184089
'ов' частота = 6073 ймовірність = 0.01183115

```

Варіант тексту	H ₁	H ₂ перекривні	H ₂ неперекривні	Різниця
3 пробілами	4.3657	3.9445	3.9442	0.0003
Без пробілів	4.4655	4.1337	4.1343	0.0005

Проаналізуємо отримані результати: Перекривний спосіб враховує кожну пару сусідніх символів, тому використовує більше даних — 1235802 біграм для тексту з пробілами та 1026612 біграм для тексту без пробілів. Неперекривний бере лише кожну другу пару, тому має 617901 та 513306 біграм відповідно. Через це його оцінка H_2 може бути трохи менш стабільною. Для тексту з пробілами різниця дуже мала ($\approx 0,0003$), а для тексту без пробілів різниця також залишається малою ($\approx 0,0005$).

Який спосіб використовує більше даних? Перекривний спосіб використовує приблизно вдвічі більше біграм, тому дає більш стабільну оцінку H_2 . Неперекривний відкидає приблизно половину можливих пар.

3. Дослідження впливу розподілу символів на ентропію

Для проведення експерименту було сформовано три послідовності достатньої довжини:

А — фрагмент природного російськомовного тексту;

Б — послідовність, утворена повторенням одного символу;

В — випадкова послідовність символів того самого алфавіту, в якій усі символи генеруються з однаковою ймовірністю.

До виконання обчислень очікуваний порядок зростання H_1 :

$B < A < V$

Послідовність Б має найменшу ентропію, оскільки містить лише один символ. У природному тексті А символи мають нерівномірний розподіл частот, тому його ентропія буде більшою. Для випадкової послідовності В символи мають приблизно однакові ймовірності, тому ентропія буде найбільшою.

Пункт виконано за допомогою скрипта lab1_3.py:

```
PS C:\Users\Admin\AppData\Local\Programs\Microsoft VS Code> & C:\Users\Admin\AppData\Local\Microsoft\Windows\AI\lab1_3.py"
=====
ДОСЛІДЖЕННЯ ВПЛИВУ РОЗПОДІЛУ СИМВОЛІВ НА ЕНТРОПІЮ
=====

Прогноз до виконання обчислень:
Б < А < В

Результати:
А — природний текст:      H1 = 4.37287864 біт/символ
Б — один символ:         H1 = -0.00000000 біт/символ
В — випадковий текст:     H1 = 5.08719469 біт/символ

Порядок отриманих значень:
Б < А < В

Довжина кожної послідовності: 100000
Результати відповідають прогнозу: True
PS C:\Users\Admin\AppData\Local\Programs\Microsoft VS Code> □
```

Отримані результати відповідають попередньому прогнозу: $B < A < V$. Ентропія послідовності Б дорівнює 0, оскільки містить лише один символ. Для природного тексту $A H_1 = 4.3729$ біт/символ, а для випадкової послідовності В $H_1 = 5.0872$ біт/символ. Отже, чим рівномірніше розподілені символи, тим більша ентропія тексту.

4. Дослідження залежностей між символами

Сформууйте дві послідовності однакової довжини, побудовані на однаковому алфавіті та з однаковими або максимально близькими частотами окремих символів:

- Г — символи розташовані у випадковому порядку;
- Д — символи утворюють виражену періодичну структуру, наприклад **abababab...**

Прогноз:

1. Значення H_1 для Г і Д повинні бути однаковими або дуже близькими, оскільки обидві послідовності мають однакові частоти окремих символів.
2. Значення H_2 повинні відрізнитися, оскільки H_2 враховує не тільки частоти символів, а й порядок їхнього розташування.
3. Менше значення H_2 очікується для Д, оскільки періодична структура **ababab...** робить появу наступного символу більш передбачуваною.
4. H_2 для перекривних і неперекривних біграм може відрізнитися, оскільки ці способи формують різні набори біграм.

Пункт виконано за допомогою скрипта lab1_4.py:

```
=====
ДОСЛІДЖЕННЯ ЗАЛЕЖНОСТЕЙ МІЖ СИМВОЛАМИ
=====

Прогноз до виконання обчислень:
1.  $H_1$  для Г і Д має бути однаковим або дуже близьким.
2.  $H_2$  для Г і Д має суттєво відрізнитися.
3. Менше  $H_2$  очікується для Д, оскільки символи мають періодичну структуру.
4.  $H_2$  для перекривних і неперекривних біграм може відрізнитися.

Результати для Г — випадковий порядок:
 $H_1 = 1.00000000$  біт/символ
 $H_2$  перекривні =  $0.99999992$  біт/символ
 $H_2$  неперекривні =  $0.99998345$  біт/символ
Різниця  $H_2 = 0.00001647$ 

Результати для Д — періодична структура:
 $H_1 = 1.00000000$  біт/символ
 $H_2$  перекривні =  $0.50000000$  біт/символ
 $H_2$  неперекривні =  $-0.00000000$  біт/символ
Різниця  $H_2 = 0.50000000$ 

Порівняння:
Різниця  $H_1 = 0.00000000$ 
Різниця  $H_2$  перекривних =  $0.49999992$ 
Різниця  $H_2$  неперекривних =  $0.99998345$ 
PS C:\Users\Admin\AppData\Local\Programs\Microsoft VS Code> █
```

Отримані результати повністю відповідають нашому прогнозу:

1. H_1 для Г і Д — прогнозували однакові або близькі значення $\rightarrow 1.0000$ і 1.0000 , прогноз підтверджено.
2. H_2 для Г і Д — прогнозували суттєву різницю $\rightarrow$ різниця становить 0.5000 для перекривних та майже 1.0000 для неперекривних біграм $\rightarrow$ прогноз підтверджено.
3. Менше H_2 для Д — прогноз підтвердився: 0.5000 (перекривні) та 0 (неперекривні), проти приблизно 1.0000 для Г.
4. Різниця між перекривними та неперекривними H_2 — прогноз також підтвердився, особливо для Д: 0.5000 .

- Чому тексти з однаковими частотами символів мають однакові або близькі H_1 ?

H_1 залежить тільки від частот окремих символів і не враховує порядок їх розташування. Тому якщо два тексти мають однаковий розподіл символів, їхні значення H_1 будуть однаковими або дуже близькими.

- Чому їхні H_2 можуть відрізнятися?

H_2 враховує частоти пар сусідніх символів — біграм. Тому навіть за однакових частот окремих символів порядок їх розташування може бути різним. У нашому експерименті послідовність Г була випадковою, а Д мала періодичну структуру **абабаб . . .**, через що розподіл біграм і значення H_2 суттєво відрізнялися.

- Яку інформацію враховує модель біграм?

Модель біграм, на відміну від моделі незалежних символів, враховує залежності між сусідніми символами та порядок їх появи. Тому вона дозволяє виявити закономірності структури джерела, які не видно при аналізі лише частот окремих символів.

5. Експериментальна оцінка ентропії джерела

h10

Лабораторная работа №1

Произвольная часть текста:
зать_я_эд

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Поле ввода символов:

Продолжить Другой

Неравенство для энтропии:
3.7916918730974< H < 4.02927507071071

Двоичная таблица угаданных символов:
00010000000000000000000000000000
01000000000000000000000000000000
00000000000000000000000000000000
00000100000000000000000000000000
00000001000000000000000000000000
~~~~~

Вероятности:

q[ 1 ] = 0.2  
q[ 2 ] = 0.02  
q[ 3 ] = 0.02  
q[ 4 ] = 0.08  
q[ 5 ] = 0.04  
q[ 6 ] = 0.12  
q[ 7 ] = 0.02  
q[ 8 ] = 0.08  
q[ 9 ] = 0.02  
q[ 10 ] = 0  
q[ 11 ] = 0.04  
q[ 12 ] = 0  
q[ 13 ] = 0.04  
q[ 14 ] = 0  
q[ 15 ] = 0.02  
q[ 16 ] = 0.04  
q[ 17 ] = 0.02  
q[ 18 ] = 0.02  
q[ 19 ] = 0  
q[ 20 ] = 0  
q[ 21 ] = 0  
q[ 22 ] = 0.02  
q[ 23 ] = 0.02  
q[ 24 ] = 0  
q[ 25 ] = 0.04  
q[ 26 ] = 0.02  
q[ 27 ] = 0  
q[ 28 ] = 0  
q[ 29 ] = 0.04  
q[ 30 ] = 0  
q[ 31 ] = 0.04  
q[ 32 ] = 0.04

Строка состояния:

h20

Лабораторная работа №1

Произвольная часть текста:  
а\_он\_взывает\_при\_эт

Использованные буквы:

Порядок n-граммы:  
5 символов  
10 символов  
15 символов  
20 символов  
25 символов  
30 символов  
35 символов  
40 символов  
45 символов  
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Поле ввода символов:

Продолжить Другой

Неравенство для энтропии:  
4.41355341757922< H < 4.00521300193678

Двоичная таблица угаданных символов:  
000000000000000000010000000000  
10000000000000000000000000000000  
00000001000000000000000000000000  
00000000000000000001000000000000  
00000000100000000000000000000000  
~~~~~

Вероятности:

q[1] = 0.14
q[2] = 0.02
q[3] = 0.02
q[4] = 0.02
q[5] = 0
q[6] = 0.02
q[7] = 0
q[8] = 0.06
q[9] = 0.06
q[10] = 0
q[11] = 0.02
q[12] = 0.04
q[13] = 0.06
q[14] = 0.02
q[15] = 0.04
q[16] = 0.1
q[17] = 0.04
q[18] = 0.04
q[19] = 0.04
q[20] = 0.04
q[21] = 0.14
q[22] = 0.02
q[23] = 0
q[24] = 0.06
q[25] = 0
q[26] = 0
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0
q[32] = 0

Строка состояния:

[illegible]

Оцінка	Отримане значення
H_1	4.3657
H_2	3.9445
$H^{(10)}$	$3.7917 < H < 4.0293$
$H^{(20)}$	$4.0052 < H < 4.4136$
$H^{(30)}$	$4.2582 < H < 4.6207$

6. Оцінювання надлишковості джерела

Модель	Ентропія, біт/символ	Надлишковість
H_1	4.3657	12.69%
H_2	3.9445	21.11%
$H^{(10)}$	$3.7917 < H < 4.0293$	$19.41\% < R < 24.17\%$
$H^{(20)}$	$4.0052 < H < 4.4136$	$11.73\% < R < 19.90\%$
$H^{(30)}$	$4.2582 < H < 4.6207$	$7.59\% < R < 14.84\%$

1. Як змінюється оцінка надлишковості при врахуванні залежностей між символами?

При врахуванні залежностей між символами ентропія зменшується, а надлишковість збільшується. У нашому випадку для H_1 надлишковість становить 12.69%, а для H_2 - 21.11%.

2. Чому природна мова має ненульову надлишковість?

Природна мова має ненульову надлишковість, оскільки символи розподілені нерівномірно та залежать один від одного. Крім того, існують орфографічні та граматичні закономірності, які роблять частину символів передбачуваними.

3. Який зв'язок існує між передбачуваністю наступних символів тексту, ентропією та надлишковістю джерела?

Чим вища передбачуваність наступного символу, тим менша ентропія джерела і тим більша його надлишковість. Тобто: більша передбачуваність $\rightarrow$ менша ентропія $\rightarrow$ більша надлишковість.

Аналіз результатів

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

У природному тексті символи мають нерівномірні частоти та залежать один від одного, тому він є більш передбачуваним. У нашому експерименті природний текст мав $H_1 = 4.3729$ біт/символ, а випадкова рівноймовірна послідовність — $H_1 = 5.0872$ біт/символ.

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

H_1 враховує лише частоти окремих символів, а H_2 додатково враховує частоти пар сусідніх символів і залежності між ними.

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ?

Так. У нашому експерименті для послідовностей Г і Д значення H_1 були однаковими та становили 1.0000, але H_2 для перекривних біграм становило приблизно 1.0000 для Г і 0.5000 для Д.

4. Як вилучення пробілів вплинуло на отримані значення ентропії?

Після вилучення пробілів ентропія збільшилась. H_1 зросло з 4.3657 до 4.4655, а H_2 — приблизно з 3.9445 до 4.1337. Це пояснюється тим, що пробіл є дуже частим і передбачуваним символом.

5. Чому оцінки H_2 , отримані за перекривними та неперекривними біграмами, можуть дещо відрізнятися?

Тому що ці способи використовують різні набори біграм. Перекривний спосіб враховує приблизно вдвічі більше даних. У нашому випадку різниця становила близько 0.0003 для тексту з пробілами та 0.0005 для тексту без пробілів.

6. Чому значення H_1 , H_2 , $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ відрізняються?

Тому що ці оцінки враховують різну кількість контексту та різні залежності між символами. H_1 враховує лише окремі символи, H_2 — сусідні пари, а $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ — довші залежності в тексті.

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?

Найкраще це демонструє експеримент із послідовностями Г і Д. При однаковому $H_1 = 1.0000$ значення H_2 суттєво відрізнялися через різний порядок символів.

8. Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації?

Природний текст має ненульову надлишковість і передбачувані залежності між символами. Тому частину інформації можна подати компактніше без втрати змісту. Чим менша ентропія, тим більший потенціал для стиснення.

Висновок

У ході виконання лабораторної роботи було досліджено ентропію російськомовного тексту та вплив різних моделей джерела на її оцінку. Було обчислено H_1 і H_2 для тексту з пробілами та без них, а також проведено експерименти з різними розподілами та залежностями між символами. Отримані результати показали, що врахування зв'язків між символами зменшує оцінку ентропії та збільшує надлишковість джерела. Також було встановлено, що природний текст є більш передбачуваним, ніж випадкова рівномовірна послідовність, що пояснює можливість його стиснення без втрати інформації.