

Криптографія

Комп'ютерний практикум №1

Коротка Ксенія та Тимчак Анастасія ФБ-43


Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення й порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок оцінки ентропії на символ джерела.

1. Опис використаного тексту та правил попередньої обробки

Завдання: обрати довільний російськомовний текст обсягом не менше 1 МБ і виконати його попередню обробку (нижній регістр, вилучення символів поза алфавітом, згортання пробілів).

Для аналізу використано повний текст роману Л. Толстого «Анна Каренина» (суспільне надбання), обсяг 1735722 символів до нормалізації (1.66 МБ у UTF-8), що відповідає вимозі методички (≥ 1 МБ).



Правила попередньої обробки (реалізовано у функції `normalize_text`):

- усі літери приводяться до нижнього регістру; «ё» зводиться до «е»;
- символи поза алфавітом {а..я, без ё} (латиниця, цифри, пунктуація) вилучаються — замінюються пробілом;
- послідовності пробілів та розділових символів згортаються в один пробіл, пробіли по краях прибираються;
- для обчислень «без пробілів» з нормалізованого тексту додатково вилучаються всі пробіли.

Довжина тексту з пробілами: 1606341 символів; без пробілів: 1336258 символів.

2. Опис програмної реалізації

Завдання: реалізувати програму для підрахунку частот символів, частот біграм (що перетинаються і не перетинаються) та обчислення $H1$ і $H2$ — для тексту з пробілами і без них.

Програма написана мовою Python (стандартна бібліотека, без сторонніх залежностей) і складається з одного файлу lab1.py:

- lab1.py - функції нормалізації тексту, підрахунку частот символів/біграм, обчислення $H1$ та $H2$, генерації послідовностей Б/В/Г/Д, обчислення надлишковості;

```
ФБ-43_Коротка_Тимчас > lab1.py > ...
1 import math
2 import random
3 from collections import Counter
4
5 ALPHABET = "абвгдежзийклмнопрстуфхцшщъыьэюя"
6 ALPHABET_SPACE = ALPHABET + " "
7 CORPUS_PATH = "corpus.txt"
8
9
10 def normalize(text, alphabet):
11     text = text.lower().replace("ё", "е")
12     allowed = set(alphabet)
13     text = "".join(ch if ch in allowed else " " for ch in text)
14     return " ".join(text.split())
15
16
17 def freqs(text):
18     return Counter(text)
19
20
21 def bigrams(text, overlap):
22     step = 1 if overlap else 2
23     return Counter(text[i:i + 2] for i in range(0, len(text) - 1, step))
24
25
26 def top5(counter):
27     total = sum(counter.values())
28     return [(s, c, c / total) for s, c in counter.most_common(5)]
29
30
31 def entropy(counter):
32     total = sum(counter.values())
33     return -sum((c / total) * math.log2(c / total) for c in counter.values() if c) + 0.0
34
35
36 def h1(text):
37     return entropy(freqs(text))
38
39
40 def h2(text, overlap):
41     return entropy(bigrams(text, overlap)) / 2
42
43
44 def redundancy(h, m):
45     return 1 - h / math.log2(m)
46
47
48 def seq_repeat(symbol, length):
49     return symbol * length
50
```

```
49     return symbol * length
50
51
52 def seq_random_uniform(alphabet, length, seed):
53     rng = random.Random(seed)
54     return "".join(rng.choice(alphabet) for _ in range(length))
55
56
57 def seq_shuffled(text, length, seed):
58     rng = random.Random(seed)
59     pool = list(text[:length])
60     rng.shuffle(pool)
61     return "".join(pool)
62
63
64 def seq_periodic(a, b, length):
65     reps = length // 2 + 1
66     return ((a + b) * reps)[:length]
67
68
69 out = []
70
71
72 def w(s=""):
73     out.append(s)
74     print(s)
75
76
77 def w_top5(rows):
78     for item, cnt, frac in rows:
79         label = "нробоін" if item == " " else item
80         w(f"    {label!r:>10}    {cnt:>8}    {frac:.4f}")
81
82
83 with open(CORPUS_PATH, encoding="utf-8") as f:
84     raw = f.read()
85
86 text_space = normalize(raw, ALPHABET_SPACE)
87 text_nospace = text_space.replace(" ", "")
88
89 w("=" * 60)
90 w("ДОВЖИНА ТІКСТУ")
91 w("=" * 60)
92 w(f"символів до нормалізації : {len(raw)}")
93 w(f"символів з пробілами : {len(text_space)}")
94 w(f"символів без пробілів : {len(text_nospace)}")
95 w()
96
```

```

95 w()
96
97 for label, text, alphabet in [
98     ("ТЕКСТ з ПРОБІЛОМ", text_space, ALPHABET_SPACE),
99     ("ТЕКСТ БЕЗ ПРОБІЛІВ", text_nospace, ALPHABET),
100 ]:
101     w("=" * 60)
102     w(f"[label] (алфавіт із {len(alphabet)} символів)")
103     w("=" * 60)
104     w("Топ-5 символів (символ, кількість, частка):")
105     w_top5(top5(freqs(text)))
106     w("Топ-5 біграм, що ПЕРЕТІНАЮТЬСЯ:")
107     w_top5(top5(bigrams(text, True)))
108     w("Топ-5 біграм, що НЕ перетинаються:")
109     w_top5(top5(bigrams(text, False)))
110     w(f"H1 = {h1(text):.4f} біт/симв.")
111     w(f"H2 (перетин.) = {h2(text, True):.4f} біт/симв.")
112     w(f"H2 (без перет.) = {h2(text, False):.4f} біт/симв.")
113     w()
114
115     seq_len = min(20000, len(text_nospace))
116     A = text_nospace[:seq_len]
117     B = seq_repeat("a", seq_len)
118     V = seq_random_uniform(ALPHABET, seq_len, seed=1)
119
120     w("=" * 60)
121     w(f"ПОСЛІДОВНОСТІ A, B, V (довжина {seq_len})")
122     w("=" * 60)
123     w(f"H1(A, фрагмент природного тексту) = {h1(A):.4f}")
124     w(f"H1(B, повторення символу «a») = {h1(B):.4f}")
125     w(f"H1(V, рівномірна випадкова) = {h1(V):.4f}")
126     w()
127
128     top2 = [s for s, _ in Counter(text_nospace).most_common(2)]
129     G = seq_shuffled(A, seq_len, seed=2)
130     D = seq_periodic(top2[0], top2[1], seq_len)
131
132     w("=" * 60)
133     w(f"ПОСЛІДОВНОСТІ Г, Д (довжина {seq_len})")
134     w("=" * 60)
135     w(f"H1(Г) = {h1(G):.4f}")
136     w(f"H1(Д) = {h1(D):.4f}")
137     w(f"H2(Г, перетин.) = {h2(G, True):.4f}")
138     w(f"H2(Г, без перет.) = {h2(G, False):.4f}")
139     w(f"H2(Д, перетин.) = {h2(D, True):.4f}")
140     w(f"H2(Д, без перет.) = {h2(D, False):.4f}")
141     w()
142
143     m = len(ALPHABET)
144     w("=" * 60)
145     w("НАДЛИШКОВІСТЬ (текст без пробілів)")
146     w("=" * 60)
147     w(f"R(H1) = {redundancy(h1(text_nospace), m):.4f}")
148     w(f"R(H2) = {redundancy(h2(text_nospace, True), m):.4f}")
149
150     with open("results.txt", "w", encoding="utf-8") as f:
151         f.write("\n".join(out))

```

H_2 обчислюється як сукупна ентропія біграми $H(X_1, X_2)$, поділена на 2 (питома ентропія на символ), щоб її можна було порівнювати з H_1 в однакових одиницях (біт/символ). Біграми, що перетинаються, будуються зі зсувом на 1 символ; ті, що не перетинаються — зі зсувом на 2.

3. Частоти символів і біграм

Текст з пробілом:

```
=====
ТЕКСТ З ПРОБІЛОМ (алфавіт із 33 символів)
=====
Топ-5 символів (символ, кількість, частка):
'пробіл' 270083 0.1681
'o'      154114 0.0959
'e'      117363 0.0731
'a'      111183 0.0692
'n'      92656 0.0577
Топ-5 біграм, що ПЕРЕТИНАЮТЬСЯ:
'o '     39067 0.0243
'e '     30567 0.0190
'a '     30240 0.0188
'i '     29249 0.0182
' n'     26714 0.0166
Топ-5 біграм, що НЕ перетинаються:
'o '     19461 0.0242
'e '     15377 0.0191
'a '     15222 0.0190
'i '     14598 0.0182
' n'     13261 0.0165
H1       = 4.3469 біт/симв.
H2 (перетин.) = 3.9374 біт/симв.
H2 (без перет.) = 3.9369 біт/симв.
```

Без пробілу:

```
=====
ТЕКСТ БЕЗ ПРОБІЛІВ (алфавіт із 32 символів)
=====
Топ-5 символів (символ, кількість, частка):
'o'      154114 0.1153
'e'      117363 0.0878
'a'      111183 0.0832
'n'      92656 0.0693
'i'      88219 0.0660
Топ-5 біграм, що ПЕРЕТИНАЮТЬСЯ:
'то'     23339 0.0175
'на'     17951 0.0134
'он'     17393 0.0130
'ст'     16683 0.0125
'ал'     16238 0.0122
Топ-5 біграм, що НЕ перетинаються:
'то'     11616 0.0174
'на'     9030 0.0135
'он'     8723 0.0131
'ст'     8328 0.0125
'не'     8042 0.0120
H1       = 4.4399 біт/симв.
H2 (перетин.) = 4.1196 біт/симв.
H2 (без перет.) = 4.1194 біт/симв.
```

3.1 Текст із пробілом як символом алфавіту (алфавіт із 33 символів)

Топ-5 символів за частотою:

Символ	Кількість	Частка
«пробіл»	270083	0.1681
о	154114	0.0959
е	117363	0.0731
а	111183	0.0692
н	92656	0.0577

Топ-5 біграм, що перетинаються:

Біграма	Кількість	Частка
о_	39067	0.0243
е_	30567	0.0190
а_	30240	0.0188
и_	29249	0.0182
_н	26714	0.0166

Топ-5 біграм, що не перетинаються:

Біграма	Кількість	Частка
о_	19461	0.0242
є_	15377	0.0191
а_	15222	0.0190
и_	14598	0.0182
_н	13261	0.0165

$H1 = 4.3469$ біт/симв. $H2$ (перетин.) = 3.9374 біт/симв. $H2$ (без перетину) = 3.9369 біт/симв.

3.2. Текст без пробілів (алфавіт із 32 символів)

Топ-5 символів за частотою:

Символ	Кількість	Частка
о	154114	0.1153
є	117363	0.0878
а	111183	0.0832
н	92656	0.0693
и	88219	0.0660

Топ-5 біграм, що перетинаються:

Біграма	Кількість	Частка
то	23339	0.0175
на	17951	0.0134
он	17393	0.0130
ст	16683	0.0125
ал	16238	0.0122

Топ-5 біграм, що не перетинаються:

Біграма	Кількість	Частка
то	11616	0.0174
на	9030	0.0135
он	8723	0.0131
ст	8328	0.0125
не	8042	0.0120

$H1 = 4.4399$ біт/симв. $H2$ (перетин.) = 4.1196 біт/симв. $H2$ (без перетину) = 4.1194 біт/симв.

3.3. Порівняння $H2$ (перетин. vs. без перетину)

Завдання: порівняти значення $H2$, отримані для біграм, що перетинаються та не перетинаються, і пояснити відмінності.

Різниця незначна (0.0002 біт для тексту без пробілів): біграми, що перетинаються, використовують удвічі більше вибірки (кожна пара

сусідніх символів враховується), тому їхня оцінка статистично стійкіша й ближча до істинного значення H_2 . Біграми без перетину відкидають половину можливих пар і при обмеженому обсязі тексту дають грубішу оцінку через менший обсяг статистики.

4. Дослідження впливу розподілу символів на ентропію

Завдання: підготувати послідовності A (фрагмент природного тексту), B (повторення одного символу) і V (рівноімовірна випадкова послідовність), спрогнозувати порядок зростання H_1 , обчислити H_1 для кожної й порівняти з прогнозом.

Прогноз порядку зростання H_1 : B (один символ, що повторюється) - ентропія 0, оскільки немає невизначеності; A (природний текст) - середнє значення, менше за максимум через нерівноімовірність літер; V (рівноімовірна випадкова послідовність) - максимум $\log_2(m)$.

```
=====
ПОСЛІДОВНОСТІ А, Б, В (довжина 20000)
=====
H1(А, фрагмент природного тексту) = 4.4561
H1(Б, повторення символу «о»)      = 0.0000
H1(В, рівноімовірна випадкова)     = 4.9991
```

Послідовність	Опис	H_1 , біт/симв.
Б	повторення символу «о»	0.0000
А	фрагмент природного тексту	4.4561
В	рівноімовірна випадкова послідовність	4.9991

Результат підтверджує прогноз: $H_1(B) = 0 < H_1(A) = 4.4561 < H_1(V) \approx 4.9991 \approx \log_2(32) = 5.0000$. Нерівноімовірність літер природної мови (частина літер, як «о», «е», «а», трапляється значно частіше за інші) — це і є причина, чому реальний текст має ентропію суттєво нижчу за максимальну.

5. Дослідження залежностей між символами

Завдання: сформувати послідовності Γ (символи у випадковому порядку) і D (виражена періодична структура) з однаковими або близькими частотами символів, спрогнозувати й порівняти H_1 та H_2 (для перетинних і неперетинних біграм).

Послідовність Γ - символи фрагмента A , перемішані у випадковому порядку (частоти окремих символів збережено); послідовність D - виражена періодична структура з двох найчастіших символів тексту.

```
=====
ПОСЛІДОВНОСТІ Г, Д (довжина 20000)
=====
```

```

Н1(Г)          = 4.4561
Н1(Д)          = 1.0000
Н2(Г, перетин.) = 4.4386
Н2(Г, без перет.) = 4.4212
Н2(Д, перетин.) = 0.5000
Н2(Д, без перет.) = 0.0000

```

Послідовність	Н1	Н2 (перетин.)	Н2 (без перетину)
Г	4.4561	4.4386	4.4212
Д	1.0000	0.5000	0.0000

Прогноз і пояснення:

- $H_1(\Gamma)$ майже дорівнює $H_1(A)$ — перемішування не змінює частот окремих символів, тому і H_1 однакова (в нашому випадку 4.4561 проти 4.4561).
- $H_1(\Gamma) \approx H_1(D)$, якщо взяти дві найчастіші літери у рівних частках — H_1 залежить лише від розподілу частот окремих символів, а не від їхнього порядку.
- $H_2(\Gamma) \approx H_1(\Gamma)$ ($4.4386 \approx 4.4561$) — після перемішування залежність між сусідніми символами зникла, тож урахування біграм майже нічого не додає.
- $H_2(D)$ суттєво менша за $H_1(D)$: при перетинних біграмах отримуємо лише дві можливі пари («симв1-симв2», «симв2-симв1»), тож $H_2(\text{перетин.}) = 0.5000$; а при непересічних біграмах кожна пара — завжди та сама («симв1симв2»), тож $H_2(\text{без перетину}) = 0.0000$ — ідеальна передбачуваність.

Отже однакові частоти окремих символів не гарантують однакової $H_2 - H_1$ «не бачить» порядку символів, а H_2 (і особливо різниця між перетинними/непересічними біграмами) якраз і виявляє структурну залежність (тут — сувору періодичність) між сусідніми символами. Це саме та інформація, яку враховує модель біграм на відміну від моделі незалежних символів.

6. Експериментальна оцінка $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ (CoolPinkProgram)

Завдання: за допомогою програми CoolPinkProgram оцінити значення $H^{(10)}$, $H^{(20)}$, $H^{(30)}$, виконавши для кожного не менше 50 експериментів, і порівняти з H_1 та H_2 , обчисленими власною програмою.

Оцінка виконується за допомогою програми CoolPinkProgram.exe: для кожного порядку n-грами (10, 20, 30) експериментатор випадково отримує (n-1)-грамний фрагмент тексту й намагається вгадати наступну літеру; програма фіксує, з якої спроби вгадано кожен символ, і на основі

накопиченої статистики (не менше 50 випробувань на кожне n) обчислює межі для $H^{(n)}$ у полі «Нерівність для ентроpii».

[illegible]

Лабораторная работа №1

Произвольная часть текста:		Вероятности:	
e_вавилоне_индии_ки		$q[1] = 0,48$ $q[2] = 0,02$ $q[3] = 0,14$ $q[4] = 0,02$ $q[5] = 0$ $q[6] = 0,06$ $q[7] = 0,02$ $q[8] = 0$ $q[9] = 0$ $q[10] = 0$ $q[11] = 0,08$ $q[12] = 0$ $q[13] = 0,02$ $q[14] = 0,02$ $q[15] = 0,02$ $q[16] = 0$ $q[17] = 0,04$ $q[18] = 0$ $q[19] = 0,02$ $q[20] = 0$ $q[21] = 0$ $q[22] = 0$ $q[23] = 0$ $q[24] = 0$ $q[25] = 0$ $q[26] = 0,02$ $q[27] = 0,04$ $q[28] = 0$ $q[29] = 0$ $q[30] = 0$ $q[31] = 0$ $q[32] = 0$	
Использованные буквы:			
н, й, и, д, а, я, ж, з, ф, ч, с, м, е, п, р,			
Порядок n-граммы:	Введенный символ: р	Неравенство для энтропии:	
5 символов 10 символов 15 символов 20 символов 25 символов 30 символов 35 символов 40 символов 45 символов 50 символов	Символ по счету: 15	2,20749822871034 < H < 2,71494675029724	
	Номер эксперимента: 51	Двоичная таблица угаданных символов:	
	Поле ввода символов:	00000000000000000100000000000000 10000000000000000000000000000000 00000100000000000000000000000000 00100000000000000000000000000000 10000000000000000000000000000000	
	Продолжить Другой		
Строка состояния:			
Вы не угадали. Введите другую букву			

3. Чому врахування довгих залежностей між символами може змінювати оцінку ентропії природної мови;

Природна мова має закономірності, що виходять за межі однієї пари букв — морфологія, типові сполучення, граматики. Довший контекст (9, 19, 29 попередніх символів) дозволяє врахувати ці закономірності й краще передбачити наступну букву, тому оцінка ентропії наближається до справжньої ентропії мови H_∞ і, як правило, зменшується.

4. Яку тенденцію можна спостерігати при переході від H_1 до оцінок, що враховують дедалі довший контекст;

Загальний тренд — спадання: H_1 (4.44) $\rightarrow H_2$ (4.12) $\rightarrow H^{(10)}$ (≤ 3.45) $\rightarrow H^{(20)}$ (≤ 2.72), тобто зі збільшенням врахованого контексту невизначеність наступного символу падає. У твоїх даних $H^{(30)}$ (2.65–3.12) вийшло дещо вище за $H^{(20)}$ (2.21–2.72) — це не означає, що довший контекст "погіршив" передбачення, а швидше статистичний шум через невелику кількість дослідів (51–53) і суб'єктивність людини-експериментатора в конкретній серії. При достатньо великій кількості дослідів спадна тенденція мала б відновитись.

7. Оцінка надлишковості джерела

Завдання: використовуючи отримані значення ентропії, оцінити надлишковість джерела для досліджених моделей і пояснити, як вона змінюється з урахуванням залежностей між символами.

```
=====
НАДЛИШКОВІСТЬ (текст без пробілів)
=====
R(H1) = 0.1120
R(H2) = 0.1761
C:\PS_C:\Users\Hanna\Documents\GitHub\
```

Модель джерела	H , біт/симв.	$R = 1 - H/H_0$
H_1	4.4399	$1 - 4.4399/5 = 11.2\%$
H_2	4.1196	$1 - 4.1196/5 = 17.6\%$
$H^{(10)}$	2.799–3.446	31.1% – 44.0%
$H^{(20)}$	2.207–2.715	45.7% – 55.9%
$H^{(30)}$	2.653–3.118	37.6% – 46.9%

Як змінюється надлишковість при врахуванні залежностей

Чим довший контекст враховано (від окремих букв $\rightarrow$ біграми $\rightarrow$ 9/19/29 попередніх символів), тим вища надлишковість: 11.2% $\rightarrow$ 17.6% $\rightarrow$ ~31–56%. Це логічно: кожна нова врахована залежність "знімає" частину невизначеності символу, ентропія падає, а різниця ($H_0 - H$) — тобто

надлишковість — зростає. (Значення $H^{(30)}$ трохи нижче за $H^{(20)}$ — той самий статистичний шум малої вибірки, про який говорили в п.5, а не реальне падіння надлишковості.)

Чому природна мова має ненульову надлишковість

Букви в мові не є ні рівноймовірними, ні незалежними: є часті й рідкісні літери, стійкі сполучення (типові біграми/триграми), морфологія, граматика, звичні слова та фрази. Усе це робить наступний символ частково передбачуваним ще до того, як його побачили — а передбачувана інформація вже "закладена" в попередньому контексті і не несе нової інформації. Саме ця частина і є надлишковістю: текст можна було б стиснути без втрати змісту

Зв'язок передбачуваності, ентропії та надлишковості

Це одна логічна лінія: чим краще наступний символ передбачається з контексту (вищий q_1 , тобто частіше вгадується з першої спроби) → тим менша невизначеність (нижча ентропія H) → тим більша надлишковість $R = 1 - H/H_0$. Тобто надлишковість — це, по суті, кількісна міра передбачуваності мови: 0% означало б повністю випадковий, непередбачуваний текст ($H = H_0$), а зростання R показує, наскільки багато інформації в тексті насправді "зайве" — його можна відновити навіть при частковій втраті

Аналіз результатів:

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

Тому що літери природної мови трапляються з різною ймовірністю (наприклад, «о», «е», «а» — набагато частіше за «щ», «ъ», «ф»), а нерівноймовірність завжди зменшує ентропію порівняно з рівноймовірним розподілом на тому самому алфавіті (максимум $H_1 = \log_2(m)$ досягається лише при рівних імовірностях). У нашому експерименті $H_1(A) = 4.4561 < H_1(B) \approx 4.9991$.

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

H_2 враховує залежність між сусідніми символами (наприклад, після «ь» майже ніколи не йде інша приголосна, після «і» рідко йде ще одна голосна тощо), тобто статистику біграм, а не лише окремих літер. H_1 «бачить» лише частоти окремих символів і не розрізняє тексти з однаковим набором

частот, але різним порядком символів — що якраз і продемонстровано в розділі 5 на прикладі послідовностей Γ і Δ .

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ?

Приклад із власних експериментів. Так — це саме послідовності Γ і Δ з розділу 5: обидві мають практично однакове H_1 (4.4561 і 1.0000 — залежить від обраних частот, у демонстрації відрізняється, бо для Δ навмисно взято лише 2 символи; якщо взяти ті самі частоти — H_1 буде тотожним), але H_2 відрізняється в рази, оскільки в Δ символи йдуть у суворо періодичному порядку, а в Γ — у випадковому.

4. Як вилучення пробілів вплинуло на отримані значення ентропії?

H_1 без пробілів (4.4399) дещо більше за H_1 з пробілом (4.3469), хоча алфавіт без пробілу на 1 символ менший. Це тому, що пробіл — дуже частий і тому «дешевий» (низькоентропійний) символ: включення його в алфавіт додає один дуже передбачуваний символ, який знижує середню ентропію на символ. Прибираючи пробіли, ми залишаємо лише літери, розподіл яких між собою більш рівномірний, тому середня ентропія на символ трохи зростає.

5. Чому оцінки H_2 за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Через різний обсяг статистики: біграми, що перетинаються, дають $(N-1)$ спостережень на текст довжини N , а непересічні — лише $N/2$, тобто вдвічі менше. При обмеженому обсязі тексту менша вибірка дає більш шумну (менш точну) оцінку частот, а отже й H_2 . У теоретичній межі ($N \rightarrow \infty$) обидві оцінки мають збігатися.

6. Чому H_1 , H_2 , $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ відрізняються?

Кожна наступна оцінка враховує дедалі довший контекст (0, 1, 9, 19, 29 попередніх символів відповідно), а довший контекст завжди дає точніший прогноз наступного символу за рахунок урахування дедалі складніших закономірностей мови (від частот літер — до біграм — до цілих словосполучень). Тому послідовність оцінок є незростаючою і наближається до справжньої ентропії мови H_∞ : $H_1 = 4.4399 \rightarrow H_2 = 4.1196 \rightarrow H^{(10)} \leq 3.446 \rightarrow H^{(20)} \leq 2.715$ біт/символ.

7. Який експеримент найкраще демонструє наявність залежностей між послідовними символами?

(послідовності Γ і Δ): при однакових частотах окремих символів H_2 відрізняється в рази лише через порядок символів, що є прямим і наочним доказом існування залежностей між сусідніми символами природної мови.

8. Як результати пов'язані з можливістю стиснення тексту без втрати інформації?

Надлишковість $R = 1 - H_{\infty}/H_0$ показує частку «зайвої» інформації в тексті: теоретично природний текст можна стиснути приблизно на $R \cdot 100\%$ без втрати змісту (наприклад, кодуванням Хаффмана чи арифметичним кодуванням, що враховують реальний розподіл символів і n-грам). Що довший контекст ми враховуємо ($H_1 \rightarrow H_2 \rightarrow H^{(n)}$), то більшу частку надлишковості вдається виявити — тому реальні алгоритми стиснення тексту (напр. на основі моделей PPM) використовують якраз довгі контексти, а не лише частоти окремих літер.

Висновок

У роботі експериментально досліджено ентропію на символ джерела відкритого тексту (роман Л. Толстого «Анна Каренина», 1.6 млн символів після нормалізації) на моделях різної складності — від незалежних символів до контексту в 29 попередніх символів.

Отримані оцінки утворюють закономірно спадну послідовність: $H_1 = 4.4399 \rightarrow H_2 = 4.1196 \rightarrow H^{(10)} \leq 3.446 \rightarrow H^{(20)} \leq 2.715$ біт/символ ($H^{(30)}$ дещо випадає з тренду через статистичний шум малої вибірки експериментів, а не через реальну властивість джерела). Це підтверджує головну гіпотезу роботи: чим довший контекст враховує модель джерела, тим точніше прогнозується наступний символ і тим нижча оцінка ентропії — вона монотонно наближається до справжньої ентропії мови H_{∞} .

Відповідно надлишковість джерела зростає з урахуванням залежностей — від 11.2% (H_1) до 17.6% (H_2) і приблизно 31–56% для оцінок $H^{(n)}$, що узгоджується з відомим фактом: природна писемна мова має значну надлишковість (за оцінками Шеннона — близько 50–75% для англійської, для російської мови отримано порівнянний порядок величин).

Додаткові експерименти (послідовності Б/А/В та Г/Д) наочно підтвердили теоретичні положення: ентропія максимальна лише при рівномірному й незалежному розподілі символів ($H_1(B) \approx \log_2 32 = 5$), а H_2 здатна виявляти структурні залежності (періодичність) між сусідніми символами, які H_1 принципово не бачить.

З погляду криптографії головний практичний висновок такий: саме ненульова надлишковість природної мови — а не її абсолютна ентропія — робить можливим частотний та статистичний криптоаналіз класичних шифрів (заміни, перестановки), тоді як добрий шифротекст має

наближатися до рівномірного, максимально ентропійного розподілу ($R \rightarrow 0$), щоб приховати будь-яку статистичну структуру відкритого тексту