

Криптографія

Комп'ютерний практикум №1

Коротка Ксенія та Тимчак Анастасія ФБ-43


Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення й порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок оцінки ентропії на символ джерела.

1. Опис використаного тексту та правил попередньої обробки

Завдання: обрати довільний російськомовний текст обсягом не менше 1 МБ і виконати його попередню обробку (нижній регістр, вилучення символів поза алфавітом, згортання пробілів).

Для аналізу використано повний текст роману Л. Толстого «Анна Каренина» (суспільне надбання), обсяг 1735722 символів до нормалізації (1.66 МБ у UTF-8), що відповідає вимозі методички (≥ 1 МБ).



Правила попередньої обробки (реалізовано у функції `normalize`):

- усі літери приводяться до нижнього регістру; «ё» зводиться до «е»;
- символи поза алфавітом {а..я, без ё} (латиниця, цифри, пунктуація) вилучаються — замінюються пробілом;
- послідовності пробілів та розділових символів згортаються в один пробіл, пробіли по краях прибираються;
- для обчислень «без пробілів» з нормалізованого тексту додатково вилучаються всі пробіли.

Довжина тексту з пробілами: 1606341 символів; без пробілів: 1336258 символів.

2. Опис програмної реалізації

Завдання: реалізувати програму для підрахунку частот символів, частот біграм (що перетинаються і не перетинаються) та обчислення $H1$ і $H2$ — для тексту з пробілами і без них.

Програма написана мовою Python (стандартна бібліотека, без сторонніх залежностей) і складається з одного файлу lab1.py:

- lab1.py - функції нормалізації тексту, підрахунку частот символів/біграм, обчислення $H1$ та $H2$, генерації послідовностей Б/В/Г/Д, обчислення надлишковості;

```
lab1.py > ...
1 import math
2 import random
3 from collections import Counter
4
5 ALPHABET = "абвгдежзийклмнопрстуфхцчшщъыьэюя"
6 ALPHABET_SPACE = ALPHABET + " "
7 CORPUS_PATH = "corpus.txt"
8
9
10 def normalize(text, alphabet):
11     text = text.lower().replace("ё", "ё")
12     allowed = set(alphabet)
13     text = "".join(ch if ch in allowed else " " for ch in text)
14     return " ".join(text.split())
15
16
17 def freqs(text):
18     return Counter(text)
19
20
21 def bigrams(text, overlap):
22     step = 1 if overlap else 2
23     return Counter(text[i:i + 2] for i in range(0, len(text) - 1, step))
24
25
26 def top5(counter):
27     total = sum(counter.values())
28     return [(s, c, c / total) for s, c in counter.most_common(5)]
29
30
31 def entropy(counter):
32     total = sum(counter.values())
33     return -sum(
34         (c / total) * math.log2(c / total)
35         for c in counter.values()
36         if c
37     ) + 0.0
38
39
40 def h1(text):
41     return entropy(freqs(text))
42
43
44 def h2(text, overlap):
45     return entropy(bigrams(text, overlap)) / 2
46
47
48 def redundancy(h, m):
49     return 1 - h / math.log2(m)
50
51
52 def seq_repeat(symbol, length):
53     return symbol * length
54
55
56 def seq_random_uniform(alphabet, length, seed):
57     rng = random.Random(seed)
58     return "".join(rng.choice(alphabet) for _ in range(length))
59
60
61 def seq_shuffled(text, seed):
62     rng = random.Random(seed)
63     pool = list(text)
64     rng.shuffle(pool)
65     return "".join(pool)
66
67
68 def seq_periodic(a, b, length):
69     reps = length // 2 + 1
70     return ((a + b) * reps)[:length]
71
72
73 out = []
74
```

```

74
75
76 def w(s=""):
77     out.append(s)
78     print(s)
79
80
81 def w_top5(rows):
82     for item, cnt, frac in rows:
83         label = "пробіл" if item == " " else item
84         w(f"{label!r:>10} {cnt:>8} {frac:.4f}")
85
86
87 with open(CORPUS_PATH, encoding="utf-8") as f:
88     raw = f.read()
89
90 text_space = normalize(raw, ALPHABET_SPACE)
91 text_nospace = text_space.replace(" ", "")
92
93 w("=" * 60)
94 w("ДОВЖИНА ТЕКСТУ")
95 w("=" * 60)
96 w(f"Символів до нормалізації: {len(raw)}")
97 w(f"Символів з пробілами: {len(text_space)}")
98 w(f"Символів без пробілів: {len(text_nospace)}")
99 w()
100
101 for label, text, alphabet in [
102     ("ТЕКСТ з ПРОБІЛАМИ", text_space, ALPHABET_SPACE),
103     ("ТЕКСТ БЕЗ ПРОБІЛІВ", text_nospace, ALPHABET),
104 ]:
105     w("=" * 60)
106     w(f"{label} (алфавіт із {len(alphabet)} символів)")
107     w("=" * 60)
108
109     w("Топ-5 символів (символ, кількість, частка):")
110     w_top5(top5(freqs(text)))
111
112     w("Топ-5 біграм, що ПЕРЕТИНАЮТЬСЯ:")
113     w_top5(top5(bigrams(text, True)))
114
115     w("Топ-5 біграм, що НЕ перетинаються:")
116     w_top5(top5(bigrams(text, False)))
117
118     w(f"H1 = {h1(text):.4f} біт/симв.")
119     w(f"H2 (перетин.) = {h2(text, True):.4f} біт/симв.")
120     w(f"H2 (без перет.) = {h2(text, False):.4f} біт/симв.")
121     w()
122
123
124 # ПОСЛІДОВНОСТІ А, Б, В
125
126 seq_len = min(20000, len(text_nospace))
127
128 A = text_nospace[:seq_len]
129
130 B = seq_repeat("Б", seq_len)
131
132 V = seq_random_uniform(
133     ALPHABET,
134     seq_len,
135     seed=1
136 )
137
138 w("=" * 60)
139 w(f"ПОСЛІДОВНОСТІ А, Б, В (довжина {seq_len})")
140 w("=" * 60)
141
142 w(f"H1(А, фрагмент природного тексту) = {h1(A):.4f}")
143 w(f"H1(Б, повторення символу «Б») = {h1(B):.4f}")
144 w(f"H1(В, рівномірна випадкова) = {h1(V):.4f}")
145 w()
146
147
```

```

147
148 # ПОСЛІДОВНОСТІ Г, Д
149
150 # Беремо дві найчастіші літери тексту
151 top2 = [s for s, _ in Counter(text_nospace).most_common(2)]
152
153 a = top2[0]
154 b = top2[1]
155
156 # Створюємо базову послідовність:
157 # половина символів а, половина символів b.
158 # Таким чином Г і Д матимуть однакові частоти символів.
159
160 base = (
161     a * (seq_len // 2)
162     + b * (seq_len - seq_len // 2)
163 )
164
165 # Г – ті самі символи, але у випадковому порядку
166 G = seq_shuffled(base, seed=2)
167
168 # Д – ті самі символи і ті самі частоти,
169 # але у строгій періодичній структурі abab...
170 D = seq_periodic(a, b, seq_len)
171
172
173 w(" " * 60)
174 w(f"ПОСЛІДОВНОСТІ Г, Д (довжина {seq_len})")
175 w(" " * 60)
176
177 w(f"Використані символи: «{a}» та «{b}»")
178 w()
179
180 w(f"H1(Г)           = {h1(G):.4f}")
181 w(f"H1(Д)           = {h1(D):.4f}")
182
183 w(f"H2(Г, перетин.) = {h2(G, True):.4f}")
184 w(f"H2(Г, без перет.) = {h2(G, False):.4f}")
185
186 w(f"H2(Д, перетин.) = {h2(D, True):.4f}")
187 w(f"H2(Д, без перет.) = {h2(D, False):.4f}")
188
189 w()
190
191 # НАДЛИШКОВІСТЬ
192
193 m = len(ALPHABET)
194
195 w(" " * 60)
196 w(f"НАДЛИШКОВІСТЬ (текст без пробілів)")
197 w(" " * 60)
198
199 w(f"R(H1) = {redundancy(h1(text_nospace), m):.4f}")
200 w(f"R(H2) = {redundancy(h2(text_nospace, True), m):.4f}")
201
202
203
204 # ЗАПИС РЕЗУЛЬТАТІВ У ФАЙЛ
205
206 with open("results.txt", "w", encoding="utf-8") as f:
207     f.write("\n".join(out))

```

H_2 обчислюється як сукупна ентропія біграми $H(X_1, X_2)$, поділена на 2 (питома ентропія на символ), щоб її можна було порівнювати з H_1 в однакових одиницях (біт/символ). Біграми, що перетинаються, будуються зі зсувом на 1 символ; ті, що не перетинаються — зі зсувом на 2.

3. Частоти символів і біграм

Текст з пробілом:

```
=====
ТЕКСТ З ПРОБІЛОМ (алфавіт із 33 символів)
=====
Топ-5 символів (символ, кількість, частка):
'пробіл' 270083 0.1681
'o'      154114 0.0959
'e'      117363 0.0731
'a'      111183 0.0692
'n'      92656  0.0577
Топ-5 біграм, що ПЕРЕТИНАЮТЬСЯ:
'o '     39067  0.0243
'e '     30567  0.0190
'a '     30240  0.0188
'i '     29249  0.0182
' n'     26714  0.0166
Топ-5 біграм, що НЕ перетинаються:
'o '     19461  0.0242
'e '     15377  0.0191
'a '     15222  0.0190
'i '     14598  0.0182
' n'     13261  0.0165
H1       = 4.3469 біт/симв.
H2 (перетин.) = 3.9374 біт/симв.
H2 (без перет.) = 3.9369 біт/симв.
```

Без пробілу:

```
=====
ТЕКСТ БЕЗ ПРОБІЛІВ (алфавіт із 32 символів)
=====
Топ-5 символів (символ, кількість, частка):
'o'      154114 0.1153
'e'      117363 0.0878
'a'      111183 0.0832
'n'      92656  0.0693
'i'      88219  0.0660
Топ-5 біграм, що ПЕРЕТИНАЮТЬСЯ:
'то'     23339  0.0175
'на'     17951  0.0134
'он'     17393  0.0130
'ст'     16683  0.0125
'ал'     16238  0.0122
Топ-5 біграм, що НЕ перетинаються:
'то'     11616  0.0174
'на'     9030   0.0135
'он'     8723   0.0131
'ст'     8328   0.0125
'не'     8042   0.0120
H1       = 4.4399 біт/симв.
H2 (перетин.) = 4.1196 біт/симв.
H2 (без перет.) = 4.1194 біт/симв.
```

3.1 Текст із пробілом як символом алфавіту (алфавіт із 33 символів)

Топ-5 символів за частотою:

Символ	Кількість	Частка
«пробіл»	270083	0.1681
о	154114	0.0959
є	117363	0.0731
а	111183	0.0692
н	92656	0.0577

Топ-5 біграм, що перетинаються:

Біграма	Кількість	Частка
о_	39067	0.0243
є_	30567	0.0190
а_	30240	0.0188
и_	29249	0.0182
_н	26714	0.0166

Топ-5 біграм, що не перетинаються:

Біграма	Кількість	Частка
о_	19461	0.0242
є_	15377	0.0191
а_	15222	0.0190
и_	14598	0.0182
_н	13261	0.0165

$H1 = 4.3469$ біт/симв. $H2$ (перетин.) = 3.9374 біт/симв. $H2$ (без перетину) = 3.9369 біт/симв.

3.2. Текст без пробілів (алфавіт із 32 символів)

Топ-5 символів за частотою:

Символ	Кількість	Частка
о	154114	0.1153
є	117363	0.0878
а	111183	0.0832
н	92656	0.0693
и	88219	0.0660

Топ-5 біграм, що перетинаються:

Біграма	Кількість	Частка
то	23339	0.0175
на	17951	0.0134
он	17393	0.0130
ст	16683	0.0125
ал	16238	0.0122

Топ-5 біграм, що не перетинаються:

Біграма	Кількість	Частка
то	11616	0.0174
на	9030	0.0135
он	8723	0.0131
ст	8328	0.0125
не	8042	0.0120

$H1 = 4.4399$ біт/симв. $H2$ (перетин.) = 4.1196 біт/симв. $H2$ (без перетину) = 4.1194 біт/симв.

3.3. Порівняння $H2$ (перетин. vs. без перетину)

Завдання: порівняти значення $H2$, отримані для біграм, що перетинаються та не перетинаються, і пояснити відмінності.

Різниця незначна (0.0002 біт для тексту без пробілів): біграми, що перетинаються, використовують удвічі більше вибірки (кожна пара

сусідніх символів враховується), тому їхня оцінка статистично стійкіша й ближча до істинного значення H_2 . Біграми без перетину відкидають половину можливих пар і при обмеженому обсязі тексту дають грубішу оцінку через менший обсяг статистики.

4. Дослідження впливу розподілу символів на ентропію

Завдання: підготувати послідовності A (фрагмент природного тексту), B (повторення одного символу) і V (рівноімовірна випадкова послідовність), спрогнозувати порядок зростання H_1 , обчислити H_1 для кожної й порівняти з прогнозом.

Прогноз порядку зростання H_1 : B (один символ, що повторюється) - ентропія 0, оскільки немає невизначеності; A (природний текст) - середнє значення, менше за максимум через нерівноімовірність літер; V (рівноімовірна випадкова послідовність) - максимум $\log_2(m)$.

```
=====
ПОСЛІДОВНОСТІ А, Б, В (довжина 20000)
=====
H1(А, фрагмент природного тексту) = 4.4561
H1(Б, повторення символу «о»)      = 0.0000
H1(В, рівноімовірна випадкова)     = 4.9991
```

Послідовність	Опис	H_1 , біт/симв.
Б	повторення символу «о»	0.0000
А	фрагмент природного тексту	4.4561
В	рівноімовірна випадкова послідовність	4.9991

Результат підтверджує прогноз: $H_1(B) = 0 < H_1(A) = 4.4561 < H_1(V) \approx 4.9991 \approx \log_2(32) = 5.0000$. Нерівноімовірність літер природної мови (частина літер, як «о», «е», «а», трапляється значно частіше за інші) — це і є причина, чому реальний текст має ентропію суттєво нижчу за максимальну.

5. Дослідження залежностей між символами

Завдання: сформувати послідовності Γ (символи у випадковому порядку) і D (виражена періодична структура) з однаковими або близькими частотами символів, спрогнозувати й порівняти H_1 та H_2 (для перетинних і неперетинних біграм).

Для побудови послідовностей Γ і D було обрано дві найчастіші літери досліджуваного тексту — «о» та «е». Обидві послідовності мають однакову довжину 20000 символів і однакові частоти окремих символів: 10000 символів «о» та 10000 символів «е».

Послідовність Г утворена випадковим перемішуванням цих символів. Послідовність Д побудована з тих самих символів і з тими самими частотами, але має виражену періодичну структуру оеоеое....

Прогноз:

Значення H_1 для послідовностей Г і Д мають бути однаковими або дуже близькими, оскільки частоти символів однакові. Значення H_2 повинні відрізнятися: для періодичної послідовності Д очікуємо менше H_2 через її передбачувану структуру. Для Г значення H_2 з перекриттям і без перекриття мають бути близькими, а для Д можуть суттєво відрізнятися.

```
=====
ПОСЛІДОВНОСТІ Г, Д (довжина 20000)
=====
Використані символи: «о» та «е»

H1(Г)           = 1.0000
H1(Д)           = 1.0000
H2(Г, перетин.) = 1.0000
H2(Г, без перет.) = 0.9999
H2(Д, перетин.) = 0.5000
H2(Д, без перет.) = 0.0000
```

Послідовність	H_1	H_2 (перетин.)	H_2 (без перетину)
Г	1.0000	1.0000	0.9999
Д	1.0000	0.5000	0.0000

Порівняння результатів із прогнозом:

Результати підтвердили прогноз. $H_1(\Gamma) = H_1(D) = 1.0000$, оскільки обидві послідовності мають однакові частоти символів.

Для випадкової послідовності Г отримано $H_2 \approx 1.0000$, а для періодичної Д - $H_2 = 0.5000$ для перетинних і $H_2 = 0.0000$ для неперетинних біграм.

Отже, H_1 враховує лише частоти окремих символів, а H_2 додатково враховує порядок і залежності між сусідніми символами.

6. Експериментальна оцінка $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ (CoolPinkProgram)

Завдання: за допомогою програми CoolPinkProgram оцінити значення $H^{(10)}$, $H^{(20)}$, $H^{(30)}$, виконавши для кожного не менше 50 експериментів, і порівняти з H_1 та H_2 , обчисленими власною програмою.

Оцінка виконується за допомогою програми CoolPinkProgram.exe: для кожного порядку n-грами (10, 20, 30) експериментатор випадково отримує (n-1)-грамний фрагмент тексту й намагається вгадати наступну літеру; програма фіксує, з якої спроби вгадано кожен символ, і на основі

накопиченої статистики (не менше 50 випробувань на кожне n) обчислює межі для $H^{(n)}$ у полі «Нерівність для ентроpii».

[illegible]

Лабораторная работа №1

Произвольная часть текста:		Вероятности:	
e_вавилоне_индии_ки		$q[1] = 0,48$ $q[2] = 0,02$ $q[3] = 0,14$ $q[4] = 0,02$ $q[5] = 0$ $q[6] = 0,06$ $q[7] = 0,02$ $q[8] = 0$ $q[9] = 0$ $q[10] = 0$ $q[11] = 0,08$ $q[12] = 0$ $q[13] = 0,02$ $q[14] = 0,02$ $q[15] = 0,02$ $q[16] = 0$ $q[17] = 0,04$ $q[18] = 0$ $q[19] = 0,02$ $q[20] = 0$ $q[21] = 0$ $q[22] = 0$ $q[23] = 0$ $q[24] = 0$ $q[25] = 0$ $q[26] = 0,02$ $q[27] = 0,04$ $q[28] = 0$ $q[29] = 0$ $q[30] = 0$ $q[31] = 0$ $q[32] = 0$	
Использованные буквы:		Неравенство для энтропии:	
н, й, и, д, а, я, ж, з, ф, ч, с, м, е, п, р,		$2,20749822871034 < H < 2,71494675029724$	
Порядок n-граммы:	Введенный символ: р	Двоичная таблица угаданных символов:	
5 символов 10 символов 15 символов 20 символов 25 символов 30 символов 35 символов 40 символов 45 символов 50 символов	Символ по счету: 15	00000000000000001000000000000000 10000000000000000000000000000000 00000100000000000000000000000000 00100000000000000000000000000000 10000000000000000000000000000000	
	Номер эксперимента: 51		
	Поле ввода символов:		
	Продолжить Другой		
Строка состояния:			
Вы не угадали. Введите другую букву			

3. Чому врахування довгих залежностей між символами може змінювати оцінку ентропії природної мови;

Природна мова має закономірності, що виходять за межі однієї пари букв — морфологія, типові сполучення, граматики. Довший контекст (9, 19, 29 попередніх символів) дозволяє врахувати ці закономірності й краще передбачити наступну букву, тому оцінка ентропії наближається до справжньої ентропії мови H_∞ і, як правило, зменшується.

4. Яку тенденцію можна спостерігати при переході від H_1 до оцінок, що враховують дедалі довший контекст;

Загальний тренд — спадання: H_1 (4.44) $\rightarrow H_2$ (4.12) $\rightarrow H^{(10)}$ (≤ 3.45) $\rightarrow H^{(20)}$ (≤ 2.72), тобто зі збільшенням врахованого контексту невизначеність наступного символу падає. У твоїх даних $H^{(30)}$ (2.65–3.12) вийшло дещо вище за $H^{(20)}$ (2.21–2.72) — це не означає, що довший контекст "погіршив" передбачення, а швидше статистичний шум через невелику кількість дослідів (51–53) і суб'єктивність людини-експериментатора в конкретній серії. При достатньо великій кількості дослідів спадна тенденція мала б відновитись.

7. Оцінка надлишковості джерела

Завдання: використовуючи отримані значення ентропії, оцінити надлишковість джерела для досліджених моделей і пояснити, як вона змінюється з урахуванням залежностей між символами.

```
=====
НАДЛИШКОВІСТЬ (текст без пробілів)
=====
R(H1) = 0.1120
R(H2) = 0.1761
C:\PS_C:\Users\Hanna\Documents\GitHub\
```

Модель джерела	H , біт/симв.	$R = 1 - H/H_0$
H_1	4.4399	$1 - 4.4399/5 = 11.2\%$
H_2	4.1196	$1 - 4.1196/5 = 17.6\%$
$H^{(10)}$	2.799–3.446	31.1% – 44.0%
$H^{(20)}$	2.207–2.715	45.7% – 55.9%
$H^{(30)}$	2.653–3.118	37.6% – 46.9%

Як змінюється надлишковість при врахуванні залежностей

Чим довший контекст враховано (від окремих букв $\rightarrow$ біграми $\rightarrow$ 9/19/29 попередніх символів), тим вища надлишковість: 11.2% $\rightarrow$ 17.6% $\rightarrow$ ~31–56%. Це логічно: кожна нова врахована залежність "знімає" частину невизначеності символу, ентропія падає, а різниця ($H_0 - H$) — тобто

надлишковість — зростає. (Значення $H^{(30)}$ у нашому експерименті вийшло дещо вище за $H^{(20)}$ — це можна пояснити статистичним шумом малої вибірки та суб'єктивністю експериментального вгадування.)

Чому природна мова має ненульову надлишковість

Букви в мові не є ні рівноймовірними, ні незалежними: є часті й рідкісні літери, стійкі сполучення (типові біграми/триграми), морфологія, граматика, звичні слова та фрази. Усе це робить наступний символ частково передбачуваним ще до того, як його побачили — а передбачувана інформація вже "закладена" в попередньому контексті і не несе нової інформації. Саме ця частина і є надлишковістю: текст можна було б стиснути без втрати змісту

Зв'язок передбачуваності, ентропії та надлишковості

Це одна логічна лінія: чим краще наступний символ передбачається з контексту (вищий q_1 , тобто частіше вгадується з першої спроби) → тим менша невизначеність (нижча ентропія H) → тим більша надлишковість $R = 1 - H/H_0$. Тобто надлишковість — це, по суті, кількісна міра передбачуваності мови: 0% означало б повністю випадковий, непередбачуваний текст ($H = H_0$), а зростання R показує, наскільки багато інформації в тексті насправді "зайве" — його можна відновити навіть при частковій втраті

Аналіз результатів:

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

Тому що літери природної мови трапляються з різною ймовірністю (наприклад, «о», «е», «а» — набагато частіше за «щ», «ъ», «ф»), а нерівноймовірність завжди зменшує ентропію порівняно з рівноймовірним розподілом на тому самому алфавіті (максимум $H_1 = \log_2(m)$ досягається лише при рівних імовірностях). У нашому експерименті $H_1(A) = 4.4561 < H_1(B) \approx 4.9991$.

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

H_2 враховує залежність між сусідніми символами (наприклад, після «ь» майже ніколи не йде інша приголосна, після «і» рідко йде ще одна голосна тощо), тобто статистику біграм, а не лише окремих літер. H_1 «бачить» лише частоти окремих символів і не розрізняє тексти з однаковим набором

частот, але різним порядком символів — що якраз і продемонстровано в розділі 5 на прикладі послідовностей Г і Д.

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ?

Так. Це демонструють послідовності Г і Д. В обох використано однакові символи «о» та «е» з однаковими частотами 50% і 50%, тому $H_1(\Gamma) = H_1(D) = 1.0000$ біт/символ. Проте порядок символів різний. У Г вони випадково перемішані, тому $H_2(\Gamma) \approx 1.0000$ біт/символ, а в Д утворюють періодичну структуру оеоео..., тому $H_2(D) = 0.5000$ для перетинних і 0.0000 для неперетинних біграм. Отже H_1 не враховує порядок символів, а H_2 враховує залежності між сусідніми символами.

4. Як вилучення пробілів вплинуло на отримані значення ентропії?

H_1 без пробілів (4.4399) дещо більше за H_1 з пробілом (4.3469), хоча алфавіт без пробілу на 1 символ менший. Це тому, що пробіл — дуже частий і тому «дешевий» (низькоентропійний) символ: включення його в алфавіт додає один дуже передбачуваний символ, який знижує середню ентропію на символ. Прибираючи пробіли, ми залишаємо лише літери, розподіл яких між собою більш рівномірний, тому середня ентропія на символ трохи зростає.

5. Чому оцінки H_2 за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Через різний обсяг статистики: біграми, що перетинаються, дають $(N-1)$ спостережень на текст довжини N , а непересічні — лише $N/2$, тобто вдвічі менше. При обмеженому обсязі тексту менша вибірка дає більш шумну (менш точну) оцінку частот, а отже й H_2 . У теоретичній межі $(N \rightarrow \infty)$ обидві оцінки мають збігатися.

6. Чому H_1 , H_2 , $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ відрізняються?

Кожна наступна оцінка враховує дедалі довший контекст (0, 1, 9, 19, 29 попередніх символів відповідно), а довший контекст завжди дає точніший прогноз наступного символу за рахунок урахування дедалі складніших закономірностей мови (від частот літер — до біграм — до цілих словосполучень). Тому послідовність оцінок є незростаючою і наближається до справжньої ентропії мови H_∞ : $H_1 = 4.4399 \rightarrow H_2 = 4.1196 \rightarrow H^{(10)} \leq 3.446 \rightarrow H^{(20)} \leq 2.715$ біт/символ.

7. Який експеримент найкраще демонструє наявність залежностей між послідовними символами?

Найкраще це демонструє експеримент із послідовностями Г і Д. Вони мають однаковий алфавіт, однакову довжину та однакові частоти окремих символів, тому H_1 для них однакова — 1.0000 біт/символ. Проте через

різний порядок символів H_2 суттєво відрізняється: для випадкової $H_2 \approx 1.0000$, а для періодичної $D = 0.5000$ або 0.0000 залежно від способу формування біграм. Це показує, що H_2 враховує залежності між сусідніми символами, яких H_1 не відображає.

8. Як результати пов'язані з можливістю стиснення тексту без втрати інформації?

Надлишковість $R = 1 - H_\infty/H_0$ показує частку «зайвої» інформації в тексті: теоретично природний текст можна стиснути приблизно на $R \cdot 100\%$ без втрати змісту (наприклад, кодуванням Хаффмана чи арифметичним кодуванням, що враховують реальний розподіл символів і n -грам). Що довший контекст ми враховуємо ($H_1 \rightarrow H_2 \rightarrow H^{(n)}$), то більшу частку надлишковості вдається виявити — тому реальні алгоритми стиснення тексту (напр. на основі моделей RPM) використовують якраз довгі контексти, а не лише частоти окремих літер.

Висновок

У роботі експериментально досліджено ентропію на символ джерела відкритого тексту (роман Л. Толстого «Анна Каренина», 1.6 млн символів після нормалізації) на моделях різної складності — від незалежних символів до контексту в 29 попередніх символів.

Отримані оцінки утворюють закономірно спадну послідовність: $H_1 = 4.4399 \rightarrow H_2 = 4.1196 \rightarrow H^{(10)} \leq 3.446 \rightarrow H^{(20)} \leq 2.715$ біт/символ ($H^{(30)}$ дещо випадає з тренду через статистичний шум малої вибірки експериментів, а не через реальну властивість джерела). Це підтверджує головну гіпотезу роботи: чим довший контекст враховує модель джерела, тим точніше прогнозується наступний символ і тим нижча оцінка ентропії — вона загалом наближається до справжньої ентропії мови H_∞ .

Відповідно надлишковість джерела зростає з урахуванням залежностей — від 11.2% (H_1) до 17.6% (H_2) і приблизно 31–56% для оцінок $H^{(n)}$, що узгоджується з відомим фактом: природна писемна мова має значну надлишковість (за оцінками Шеннона — близько 50–75% для англійської, для російської мови отримано порівнянний порядок величин).

Додаткові експерименти (послідовності Б/А/В та Г/Д) наочно підтвердили теоретичні положення: ентропія максимальна лише при рівномірному й незалежному розподілі символів ($H_1(B) \approx \log_2 32 = 5$), а H_2 здатна виявляти структурні залежності (періодичність) між сусідніми символами, які H_1 принципово не бачить.

З погляду криптографії головний практичний висновок такий: саме ненульова надлишковість природної мови — а не її абсолютна ентропія — робить можливим частотний та статистичний криптоаналіз класичних шифрів (заміни, перестановки), тоді як добрий шифротекст має наближатися до рівноймовірного, максимально ентропійного розподілу ($R \rightarrow 0$), щоб приховати будь-яку статистичну структуру відкритого тексту