

Міністерство освіти і науки України
Національний технічний університет України
"Київський політехнічний інститут імені Ігоря
Сікорського"

Криптографія

Комп'ютерний практикум No1

Експериментальна оцінка ентропії на символ
джерела відкритого тексту

Виконали:
Студенти групи ФБ-42:

М`якенький Антон, Кисельова Єлизавета

Київ – 2026

1. Підготовка тексту

Текст, наданий у репозиторії курсу, мав дивне кодування: утиліта `file` показала ISO-8859, хоча фактично було CP866. За допомогою команди `iconv -from-code CP866 TEXT > TEXT_UTF8` я створив новий файл з коректним кодуванням. Для роботи з текстом використовувався саме цей файл

Для підготовки тексту в самій програмі написав таку функцію, спираючись на вимоги у методичних матеріалах

```
def preprocess(filename):
    file = open(filename, "r")
    text = file.read()
    text = text.lower()
    text = sub(r'^а-яё\s', '', text) # only russian
    text = sub(r'\s+', ' ', text) # only spaces
    text_nospaces = sub(r' ', '', text)
    return (text, text_nospaces)
```

2. Розрахунок статистичних характеристик тексту

Для підрахунку частот символів/біграм функції послідовно проходять весь текст, підраховують наявні символи/біграми через словник, а потім ділять підраховане на кількість символів/біграм

H_1 та H_2 за основу використовують ці формули з методичних матеріалів:

$$H_n = 1/n H(x_1, x_2, \dots, x_n)$$

$$H(x_1, x_2, \dots, x_n) = \sum_{z_1, z_2, \dots, z_n} P(x_1 = z_1, \dots, x_n = z_n) \log_2(P(x_1 = z_1, \dots, x_n = z_n))$$

Результати обчислень:

```
> python lab1.py
For text with spaces
Symbols
Most common: {' ': 0.14104568351572, 'o': 0.0913670314399861, 'e': 0.0771235018238666, 'и': 0.07104394649991315, 'a': 0.06531179433732846}
H_1: 4.3853542978664874
Bigrams
Most common: {'e ': 0.020674079221681723, 'cr': 0.017720639332870047, 'и ': 0.017373175816539264, ' c': 0.015983321751216122, 'a ': 0.015288394718554551}
H_2: 3.914743461832839
Bigrams (no intersection)
Most common: {'e ': 0.021542738012508687, 'cr': 0.01980542043085476, 'a ': 0.01633078526754691, 'но': 0.015635858234885336, ' в': 0.015288394718554551}
H_2: 3.8839674721837936
For text without spaces
Symbols
Most common: {'o': 0.10637007077856421, 'e': 0.0897876643073812, 'и': 0.08270980788675429, 'a': 0.07603640040444894, 'н': 0.07421638018200202}
H_1: 4.42210185111123
Bigrams
Most common: {'cr': 0.02063106796116505, 'но': 0.017597087378640776, 'en': 0.01476537216828479, 'pa': 0.013551779935275081, 'на': 0.011933656957928803}
H_2: 4.020772983776025
Bigrams (no intersection)
Most common: {'cr': 0.019417475728155338, 'но': 0.0186084142394822, 'en': 0.014563106796116505, 'pa': 0.013349514563106795, 'ни': 0.012944983818770227}
H_2: 3.974883235762987
```

Значення H_2 для біграм, що не перетинаються, є трохи меншими, ніж для тих, що перетинаються. Це можна пояснити тим, що при підрахунку на біграмах, що не перетинаються, використовується вдвічі менше статистичних даних.

3. Дослідження впливу розподілу символів на ентропію

Прогноз перед обчисленням: $B < A < C$, оскільки повторення одного й того самого символу дасть нульову ентропію, а рівномірний розподіл символів дасть максимальну.

Результат обчислення:

```
for A: 4.3853542978664874
for B: -0.0
for C: 5.083935454861411
```

Як і очікувалося, повторення того самого символу дає 0, а випадкові символи мають найбільшу.

Бачимо такий результат, оскільки ентропія є “мірою невизначеності”. Коли один символ повторюється, ми маємо вироджений розподіл, який не має невизначеності. Коли всі символи випадкові, ми не можемо нічого сказати про наступні символи, виходячи із попередніх, а отже, ентропія буде максимально можливою.

4. Дослідження залежностей між символами

Прогноз (до обчислень):

1. Чи повинні суттєво відрізнятися значення H_1 для послідовностей Г і Д?
Ні, H_1 для Г і Д будуть однаковими або дуже близькими, якщо частоти окремих символів збігаються, бо H_1 залежить тільки від частот символів, а не від їхнього порядку.
2. Чи повинні суттєво відрізнятися значення H_2 ?
Так, H_2 для Г і Д будуть суттєво відрізнятися, бо у періодичній послідовності Д (типу абабаб...) біграми сильно обмежені (мало різних пар), а у випадковій Г біграми розподілені майже рівномірно, їх більше отже і більша ентропія.
3. Для якої послідовності очікуємо менше значення H_2 ?
Менше H_2 буде у Д (періодичної), бо періодична структура дає менше можливих біграм, отже менше невизначеності.

4. Чи відрізнятимуться H_2 для біграм, що перетинаються і не перетинаються?

Так, H_2 для перетинних біграм буде більшою, ніж для неперетинних, бо перетинні біграми враховують більше переходів між символами, неперетинні це «грубіша» модель, яка втрачає частину інформації.

Отримані результати:

```
=== Sequence D (periodic) ===  
H1(D) = 1.0  
H2(D, intersect) = 0.4999996386037484  
H2(D, non-intersect) = 0.24988903481740024  
=== Sequence G (random) ===  
H1(G) = 1.0  
H2(G, intersect) = 0.9999381899972155  
H2(G, non-intersect) = 0.7500195828917772
```

Порівняння з прогнозом:

1. H_1 для Г і Д

$H_1(D)=H_1(G)=1.0$. Це підтверджує прогноз, H_1 не відрізняється, бо частоти символів однакові.

2. H_2 для Г і Д

$H_2(D)\approx 0.50$, $H_2(G)\approx 1.00$. Це також підтверджує прогноз, H_2 суттєво відрізняється, у періодичної послідовності ентропія менша.

3. Менше H_2 у Д чи Г?

H_2 менше у Д. Це збігається з прогнозом, періодична структура означає меншу кількість можливих біграм отже і меншу ентропію.

Теоретичні пояснення:

1. Чому тексти з однаковими частотами окремих символів можуть мати однакові або близькі значення H_1 ?

Бо модель H_1 (незалежні символи) враховує тільки те, як часто зустрічається кожен символ, і повністю ігнорує порядок. Якщо в двох послідовностях частоти «а» і «б» однакові (наприклад, 50/50), то H_1 буде однаковою, навіть якщо одна послідовність випадкова, а інша строго періодична.

2. Чому їхні значення H_2 можуть відрізнятися?

Бо модель біграм (H_2) враховує залежності між сусідніми символами. У випадковій послідовності Γ біграми розподілені більш рівномірно, багато різних пар дає високу ентропію. У періодичній послідовності Δ біграми сильно обмежені (наприклад, тільки аб і ба, або навіть лише аб), це дає менше варіантів отже і меншу ентропію.

3. Яку інформацію про джерело дозволяє врахувати модель біграм порівняно з моделлю незалежних символів?

Модель незалежних символів (H_1) бачить тільки «які символи і як часто» і не бачить структуру, порядок, залежності. В свою чергу модель біграм (H_2) враховує ймовірність переходу від одного символу до іншого, бачить шаблони, періодичність, структуру мови і може відрізнити випадковий текст від структурованого, навіть якщо частоти символів однакові. Тобто модель біграм дає більше інформації про джерело, бо враховує не тільки «що приходить», а й «як це пов'язано між собою».

5. Експериментальна оцінка ентропії джерела

50 експериментів для $H^{(10)}$ з CoolPinkProgram:

Произвольная часть текста:
говоря_не

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:
Символ по счету:
Номер эксперимента: 51
Поле ввода символов:

Продолжить Другой

Неравенство для энтропии:
2,3509749123852 < H < 3,00547111249554
Двоичная таблица угаданных символов:
01000000000000000000000000000000
10000000000000000000000000000000
00000010000000000000000000000000
00100000000000000000000000000000
00000000000000000000000001000000
00000000000000010000000000000000
00100000000000000000000000000000

Вероятности:
q[1] = 0,36
q[2] = 0,26
q[3] = 0,06
q[4] = 0,02
q[5] = 0,02
q[6] = 0
q[7] = 0,04
q[8] = 0
q[9] = 0,02
q[10] = 0,02
q[11] = 0
q[12] = 0
q[13] = 0
q[14] = 0,02
q[15] = 0,04
q[16] = 0
q[17] = 0
q[18] = 0
q[19] = 0
q[20] = 0
q[21] = 0
q[22] = 0
q[23] = 0,02
q[24] = 0,02
q[25] = 0,02
q[26] = 0
q[27] = 0,02
q[28] = 0,02
q[29] = 0
q[30] = 0,02
q[31] = 0
q[32] = 0,02

50 експериментів для $H^{(20)}$ з CoolPinkProgram:

Произвольная часть текста:		Вероятности:	
его_инстинктивно_и_			
Использованные буквы:			
Порядок n-граммы:	Введенный символ:	Неравенство для энтропии:	
5 символов		2,41034201114373 < H < 2,82695389502378	
10 символов	Символ по счету:		
15 символов		Двоичная таблица угаданных символов:	
20 символов	Номер эксперимента: 51		
25 символов			
30 символов	Поле ввода символов:		
35 символов			
40 символов			
45 символов			
50 символов	Продолжить Другой		

50 експериментів для $H^{(30)}$ з CoolPinkProgram:

Произвольная часть текста:		Вероятности:	
тие_o_добр_е_и_зл_е_н_е_в_больш_е		q[1]=0,24 q[2]=0,4 q[3]=0,1 q[4]=0,02 q[5]=0 q[6]=0 q[7]=0 q[8]=0,02 q[9]=0,02 q[10]=0,02 q[11]=0 q[12]=0,04 q[13]=0,06 q[14]=0 q[15]=0,02 q[16]=0 q[17]=0 q[18]=0 q[19]=0,04 q[20]=0 q[21]=0 q[22]=0 q[23]=0 q[24]=0 q[25]=0,02 q[26]=0 q[27]=0 q[28]=0 q[29]=0 q[30]=0 q[31]=0 q[32]=0	
Использованные буквы:			
Порядок n-граммы:	Введенный символ:	Неравенство для энтропии:	
5 символов 10 символов 15 символов 20 символов 25 символов 30 символов 35 символов 40 символов 45 символов 50 символов	Символ по счету:	2,36878180206534 < H < 2,6474033921147	
	Номер эксперимента: 51	Двоичная таблица угаданных символов:	
	Поле ввода символов:	00000000010000000000000000000000 10000000000000000000000000000000 00100000000000000000000000000000 01000000000000000000000000000000 01000000000000000000000000000000 10000000000000000000000000000000 01000000000000000000000000000000	  
	Продолжить Другой		

З попередніх пунктів ми дізнавались H_1 та H_2 для тексту з пробілами.

Отже таблиця:

Оцінка	Отримане значення
H_1	4.38
H_2	3.91
$H^{(10)}$	2.35
$H^{(20)}$	2.41
$H^{(30)}$	2.37

1. Чому наведені оцінки ентропії не повинні збігатися?

Оцінки ентропії отримані за різними моделями джерела:

- H_1 це модель незалежних символів, враховує тільки частоти окремих букв.
- H_2 це модель біграм, враховує залежність символу від попереднього.
- $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ це моделі з довгим контекстом, які враховують залежності на рівні 10, 20, 30 символів. Довший контекст робить текст більш передбачуваним, тому оцінки ентропії менші, ніж H_1 та H_2 .

Оскільки кожна модель враховує різний обсяг статистичної інформації, їхні значення ентропії не повинні збігатися.

2. Які статистичні залежності враховуються при визначенні H_1 та H_2 ?

H_1 враховує тільки частоти окремих символів і припускає їхню незалежність. H_2 враховує частоти пар символів (біграм), тобто залежність символу від попереднього, це ланцюг Маркова першого порядку.

3. Чому врахування довгих залежностей між символами може змінювати оцінку ентропії природної мови?

У природній мові символи залежать не лише від одного попереднього, а від ширшого контексту, наприклад структури слова, морфології, синтаксису, сталих фраз і загальної семантики. Коли модель враховує довгий контекст (10, 20, 30

символів), вона краще «бачить» ці закономірності. Це робить наступний символ більш передбачуваним, зменшує невизначеність і, відповідно, знижує оцінку ентропії. Тому моделі з довгим контекстом дають менші значення ентропії, ніж H_1 та H_2 .

4. Яку тенденцію можна спостерігати при переході від H_1 до оцінок з довшим контекстом?

При переході від моделі незалежних символів (H_1) до моделей, що враховують залежності (H_2), а далі і до моделей з довгим контекстом ($H^{(10)}$, $H^{(20)}$, $H^{(30)}$), спостерігається зменшення ентропії. Це пов'язано з тим, що довший контекст робить наступний символ більш передбачуваним, модель «бачить» структуру слова, морфологію, синтаксис і сталі фрази. Чим більше інформації про попередні символи враховується, тим менше невизначеність і тим нижча оцінка ентропії. Тому $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ менші за H_1 та H_2 .

6. Оцінювання надлишковості джерела

Формула: $H_{max} = \log_2(N)$. $N = 34$ (33 літери та +1 враховуючи пробіли).

$$H_{max} \approx 5$$

$$R = 1 - \frac{H}{H_{max}} = 1 - \frac{H}{5}$$

Таблиця надлишковості:

Оцінка	H	Надлишковість (R)
H_1	4.38	0.124
H_2	3.91	0.218
$H^{(10)}$	2.35	0.53
$H^{(20)}$	2.41	0.518
$H^{(30)}$	2.37	0.526

1. Як змінюється оцінка надлишковості при врахуванні залежностей між символами?

H_1 враховує тільки частоти символів, тому ентропія найбільша, а надлишковість найменша. H_2 враховує залежність від попереднього символа, тому ентропія зменшується, а надлишковість зростає. $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ враховують довгі залежності, тому ентропія ще менша, а надлишковість найбільша. Враховуючи отримані дані, надлишковість найбільша у моделей з довгим контекстом ($H^{(10)}$, $H^{(20)}$, $H^{(30)}$) і менша у простіших моделей (H_1 , H_2).

2. Чому природна мова має ненульову надлишковість?

Бо природна мова містить повтори, має граматичні правила, має обмеження на можливі послідовності символів, не використовує всі символи однаково часто, має структуру (слова, морфеми, синтаксис). Це робить текст передбачуваним, а передбачуваність зменшує ентропію, а надлишковість > 0 .

3. Який зв'язок існує між передбачуваністю наступних символів тексту, ентропією та надлишковістю джерела?

Якщо наступний символ легко передбачити, ентропія низька, надлишковість висока. Якщо символи майже випадкові, ентропія висока, надлишковість низька.

$$R = 1 - \frac{H}{H_{max}}$$
 — чим менше H тим більше R , і навпаки, чим більше H тим менше R .

Аналіз результатів :

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

Тому що природний текст має закономірності між символами, яка знижує ентропію відносно повністю випадкових даних

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

H_2 враховує порядок символів у тексті, а H_1 — лише ймовірність символу незалежно від порядку

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ? Наведіть приклад із виконаних експериментів.

Дані з пункту 4:

```

Sequence D (periodic)
H1(D) = 1.0
H2(D, intersect) = 0.4999996386037484
H2(D, non-intersect) = 0.24988903481740024
Sequence G (random)
H1(G) = 1.0
H2(G, intersect) = 0.9995565007266104
H2(G, non-intersect) = 0.750138563538975

```

$H_1(D)=H_1(G)$, бо частоти символів однакові. Але $H_2(D)<H_2(G)$, бо в D є жорстка періодична структура, а в G випадковий порядок. Це прямо показує що два тексти можуть мати однакове H_1 , але різне H_2 , якщо їхня внутрішня структура (залежності між символами) різна.

4. Як вилучення пробілів вплинуло на отримані значення ентропії? Поясніть отриманий результат.

For text with spaces	For text without spaces
Symbols	Symbols
Most common: {' ': 0.141}	Most common: {'o': 0.106}
H_1: 4.3853542978664874	H_1: 4.42210185111123
Bigrams	Bigrams
Most common: {'e ': 0.02}	Most common: {'ст': 0.02}
H_2: 3.914743461832839	H_2: 4.020772983776025

З отриманих даних видно, що значення ентропії і для H_1 , і для H_2 трохи збільшилось. Вилучення пробілів збільшує ентропію, оскільки пробіли є дуже частим і структурним символом, який робить текст більш передбачуваним. Після їх видалення частоти символів вирівнюються, кількість можливих біграм зростає, а регулярність тексту зменшується. Це підвищує невизначеність наступного символу, що й призводить до збільшення значень.

5. Чому оцінки H_2 , отримані за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Біграми, що не перетинаються, використовують вдвічі менше статистичних даних, ніж ті, що перетинаються

6. Чому значення H_1 , H_2 , $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ відрізняються?

H_1 – модель незалежних символів.

H_2 – модель біграм (залежність від одного попереднього символу).

$H(10), H(20), H(30)$ – експериментальні оцінки через «гру у вгадування» з довгим контекстом, інша методика.

Різні моделі джерела означають різні способи врахування статистики отже і різні значення ентропії. Тому вони не зобов'язані збігатися й відображають різні аспекти структури тексту.

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?

Найяскравіший експеримент це пара D та G:

```
Sequence D (periodic)
H1(D) = 1.0
H2(D, intersect) = 0.4999996386037484
H2(D, non-intersect) = 0.24988903481740024
Sequence G (random)
H1(G) = 1.0
H2(G, intersect) = 0.9995565007266104
H2(G, non-intersect) = 0.750138563538975
```

Частоти символів однакові, отже і $H1$ однакове. Але структура різна: D – жорстко періодична, G – випадкова. $H2$ різко падає для D, бо наступний символ майже завжди передбачуваний. Це найкраща демонстрація того, що залежності між символами сильно впливають на ентропію, і $H2$ їх ловить.

8. Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації?

Природний текст має низьке $H1$ порівняно з випадковим, тому багато надлишковості. $H2$ і довгі контекстні оцінки показують, що наступні символи передбачувані. Надлишковість R для наших моделей становить понад 50–60%. Висока надлишковість означає, що текст містить повторювані структури, які можна закодувати коротше (стиснути). Оскільки символи й біграми мають нерівномірні частоти, можна використовувати ентропійне кодування (Хаффман, арифметичне) і досягати стиску. Чим нижча ентропія (і вища надлишковість), тим більший потенціал стиску без втрати інформації. Експерименти показують, що природний текст далеко від випадковості, отже його можна суттєво стискати.