

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ» ФІЗИКО-ТЕХНІЧНИЙ
ІНСТИТУТ

КРИПТОГРАФІЯ КОМП'ЮТЕРНИЙ ПРАКТИКУМ №1

**Експериментальна оцінка ентропії на символ джерела відкритого
тексту**

Мета роботи: Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Студенток групи ФБ-42
Белінської Єлизавети та Бурмай Юлії

Порядок виконання роботи

1. Підготовка тексту

Для проведення експерименту використано довільний текст російською мовою обсягом понад 1 МБ. Текст збережено у текстовому файлі `text.txt` у кодуванні UTF-8.

Попередня обробка тексту виконується у декілька етапів:

```
def load_text(path):
    with open(path, encoding="utf-8") as f:
        text = f.read().lower().replace("ё", "е")
    return re.sub(f"^[{ALPHABET}]+", " ", text).strip()

def entropy(counter):
    total = sum(counter.values())
    return abs(sum(c / total * math.log2(c / total) for c in counter.values()))

def ngrams(text, n, step):
    return Counter(text[i:i + n] for i in range(0, len(text) - n + 1, step))

def h1(text):
    return entropy(Counter(text))

def h2(text, step):
    return entropy(ngrams(text, 2, step)) / 2

def redundancy(h, m):
    return 1 - h / math.log2(m)

def show(item):
    return item.replace(" ", "_")

def print_top(counter, k=5):
    total = sum(counter.values())
    for item, c in counter.most_common(k):
        print(f" {show(item):<4} {c:>9} {c / total:.6f}")
```

1. Переведення у нижній регістр.

За допомогою методу `.lower()` усі літери тексту переводяться у нижній регістр. Це дозволяє не розглядати, наприклад, А та а як різні символи.

2. Заміна символу «ё».

Символ ё замінюється на е за допомогою `.replace("ё", "е")`. Таким чином, обидва варіанти однієї літери враховуються як один символ.

3. Вилучення символів, що не належать до заданого алфавіту.

У програмі задано алфавіт:

абвгдежзийклмнопрстуфхцчшщъыьэюя.

За допомогою регулярного виразу всі символи, які не входять до цього алфавіту, замінюються одним пробілом:

```
re.sub(f"[^{ALPHABET}]+", " ", text).
```

При цьому послідовність із декількох сторонніх символів, наприклад розділових знаків, також замінюється одним пробілом.

4. Видалення пробілів на початку та в кінці.

Метод `.strip()` видаляє зайві пробіли на початку та в кінці отриманого тексту.

5. Формування двох варіантів тексту.

Після нормалізації створюється текст із пробілами, у якому пробіл розглядається як окремий символ алфавіту. Для другого варіанта всі пробіли вилучаються за допомогою:

```
text_no_spaces = text.replace(" ", "").
```

2. Розрахунок статистичних характеристик тексту

Прогноз

- $N_1 < N_0$, бо літери нерівноймовірні.
- $N_2 < N_1$, бо сусідні літери залежні.
- Без пробілів N_1 зросте (пробіл був найчастішим символом і робив розподіл нерівномірнішим).
- N_2 з перетином і без перетину майже збігатимуться, бо текст великий.

Результати:

```
Після обробки: 889641 символів, без пробілів: 746137
ТЕКСТ З ПРОБІЛАМИ
Символів: 889641, різних: 33, m = 33, H0 = 5.044394
H1 = 4.385508 R = 0.130618
H2 (перетин) = 3.969104 R = 0.213165
H2 (без перетину) = 3.968870 R = 0.213212
```

```
ТЕКСТ БЕЗ ПРОБІЛІВ
Символів: 746137, різних: 32, m = 32, H0 = 5.000000
H1 = 4.468950 R = 0.106210
H2 (перетин) = 4.138761 R = 0.172248
H2 (без перетину) = 4.138674 R = 0.172265
```

Прогноз справдився

Для кожного випадку визначте п'ять символів та п'ять біграм із найбільшими частотами.

З пробілами:

```
52 def analyze(text, tag, m):
53     chars = Counter(text)
54     bi_over = ngrams(text, 2, 1)
55     bi_non = ngrams(text, 2, 2)
56     res = {
57         "H1": entropy(chars),
58         "H2 (перетин)": entropy(bi_over) / 2,
59         "H2 (без перетину)": entropy(bi_non) / 2,
60     }
61
62     print(f"ТЕКСТ {tag.upper()}")
63     print(f"Символів: {len(text)}, різних: {len(chars)}, m = {m}, H0 = {math.log2(m):.6f}")
64     for name, value in res.items():
65         print(f"{name} = {value:.6f} R = {redundancy(value, m):.6f}")
66
67     if res["H1"] > math.log2(m) or res["H2 (перетин)"] > res["H1"] + 1e-3:
68         print("УВАГА: H1 > H0 або H2 > H1, перевірте обробку тексту")
69
70     print("\nТоп-5 символів:")
71     print_top(chars)
72     print("\nТоп-5 біграм (перетин):")
73     print_top(bi_over)
74     print("\nТоп-5 біграм (без перетину):")
75     print_top(bi_non)
76
77     return res
```

```

Топ-5 символів:
_      143504  0.161306
о      84337  0.094799
е      64018  0.071959
а      56838  0.063889
и      51609  0.058011

Топ-5 біграм (перетин):
о_     18795  0.021127
е_     16476  0.018520
и_     16221  0.018233
_п     15082  0.016953
_н     13840  0.015557

Топ-5 біграм (без перетину):
о_     9480  0.021312
е_     8259  0.018567
и_     8084  0.018174
_п     7524  0.016915
_н     6917  0.015550

```

Без пробілів:

```

Топ-5 символів:
о      84337  0.113032
е      64018  0.085799
а      56838  0.076176
и      51609  0.069168
н      46349  0.062119

Топ-5 біграм (перетин):
то     11821  0.015843
ов     9717  0.013023
ко     9614  0.012885
ст     9531  0.012774
но     8743  0.011718

Топ-5 біграм (без перетину):
то     5923  0.015876
ов     4795  0.012853
ко     4756  0.012748
ст     4699  0.012596
но     4340  0.011633

```

Порівняйте значення H_2 , отримані для біграм, що перетинаються та не перетинаються.

Результати майже однакові (різниця 0,0002 і 0,0001 біта). Обидва способи оцінюють один і той самий розподіл біграм. Більше даних використовує спосіб з перетином: $\approx N$ біграм замість $\approx N/2$. Кожна літера бере участь у двох біграмах, тому статистика вдвічі повніша й стабільніша.

Чому різниця все ж є. Вибірка кінцева, тому частоти трохи плывуть. Крім того, біграми без перетину залежать від того, з якої позиції почати (парної чи непарної). Для короткого тексту різниця була б помітнішою.

Чому вона така мала. Текст великий (~ 890 тис. символів проти ~ 1000 можливих біграм), тож обидві оцінки вже близькі до істинного значення. Але сусідні біграми частково залежні (мають спільну літеру), тож це не незалежна вибірка. Але для оцінки частот це не шкодить.

Без пробілів H_1 зростає з 4,39 до 4,47, а H_2 з 3,97 до 4,14. Це підтвердило прогноз. Пробіл займає 16 % тексту і робив розподіл нерівномірнішим. Крім того, він сам дуже передбачуваний, бо стоїть після типових закінчень (о, е, и) і перед типовими початками (п, н). Прибравши його, ми прибравли найпередбачуваніший елемент.

Топ біграм теж змінився: без пробілів вони стали суто літерними (то, ов, ко), бо біграми з пробілом зникли.

3. Дослідження впливу розподілу символів на ентропію

```
79
80 def section3(text_no_spaces):
81     n = min(SEQ_LEN, len(text_no_spaces))
82     sequences = {
83         "А (природний текст)": text_no_spaces[:n],
84         "Б (один символ)": "а" * n,
85         "В (рівномовірна)": "".join(random.choices(ALPHABET, k=n)),
86     }
87     print("3. ВПЛИВ РОЗПОДІЛУ СИМВОЛІВ")
88     print(f"Довжина: {n}, log2({len(ALPHABET)}) = {math.log2(len(ALPHABET)):.6f}")
89     for name, seq in sequences.items():
90         print(f"{name}: H1 = {h1(seq):.6f}, H2 (перетин) = {h2(seq, 1):.6f}")
91
```

Прогноз

$B < A < V$

Б: символ завжди один, вгадувати нічого, невизначеності нема. $H_1 = 0$.

А: літери нерівноймовірні (о, е, а трапляються часто, ф, щ, ь рідко), тож частину символів вгадати легше. H_1 нижче максимуму, але не нуль.

В: усі літери рівноймовірні, невизначеність максимальна. $H_1 \approx \log_2 32 = 5$ біт.

3. ВПЛИВ РОЗПОДІЛУ СИМВОЛІВ

Довжина: 100000, $\log_2(32) = 5.000000$

А (природний текст): $H_1 = 4.479168$, H_2 (перетин) = 4.133287

Б (один символ): $H_1 = 0.000000$, H_2 (перетин) = 0.000000

В (рівноймовірна): $H_1 = 4.999821$, H_2 (перетин) = 4.996231

Прогноз справдився: $B(0) < A(4,48) < V(5,00)$.

Б: дало точно 0, бо розподіл вироджений.

В: майже дорівнює максимуму 5. Відхилення 0,0002 впливає з випадковості вибірки (частоти не рівно по 1/32).

А: лежить між ними: 4,48 проти 5,00, тобто на $\approx 0,5$ біта нижче за максимум.

Ентропія залежить від того, наскільки рівномірний розподіл символів: чим нерівномірніший розподіл, тим менша ентропія, рівномірний розподіл дає максимум, вироджений дає нуль.

Природний текст має нерівномірний розподіл літер, тому його ентропія менша за випадкову.

4. Дослідження залежностей між символами

```
93 def section4():
94     periodic = "ab" * (SEQ_LEN // 2)
95     chars = list(periodic)
96     random.shuffle(chars)
97     sequences = {"Г (випадкова)": "".join(chars), "Д (періодична)": periodic}
98     print("4. ЗАЛЕЖНОСТІ МІЖ СИМВОЛАМИ")
99     for name, seq in sequences.items():
100         print(f"\n{name}: частоти символів {dict(Counter(seq))}")
101         print(f"    біграми (перетин): {dict(ngrams(seq, 2, 1))}")
102         print(f"    біграми (без перетину): {dict(ngrams(seq, 2, 2))}")
103         print(f"    H1 = {h1(seq):.6f}")
104         print(f"    H2 (перетин) = {h2(seq, 1):.6f}")
105         print(f"    H2 (без перетину) = {h2(seq, 2):.6f}")
106
```

Робимо прогноз:

1. Чи повинні суттєво відрізнятися значення H_1 для послідовностей Г і Д:
 H_1 залежить лише від частот символів. Порядок символів на H_1 не впливає.
2. Чи повинні суттєво відрізнятися значення H_2 :
 - так
 У Г символи незалежні, тому всі 4 біграми (aa, ab, ba, bb) майже рівномірні, по 1/4. Тоді $H(\text{біграм}) = 2$ біт і $H_2 \approx 1$.
 У Д після а завжди йде b, а після b завжди а. При кроці 1 можливі лише дві біграми (ab, ba), по 1/2. Тоді $H(\text{біграм}) = 1$ біт і $H_2 = 0,5$.
3. Для якої послідовності ви очікуєте менше значення H_2 .
 Для Д. Вона повністю передбачувана, тож невизначеності менше.
4. Чи відрізнятимуться H_2 обчислене для біграм що перетинаються і що не перетинаються
 Для Г майже ні, бо порядок випадковий і біграми з будь-якого кроку мають однаковий розподіл (різниця лише на рівні статистичного шуму).
 Для Д суттєво. При кроці 2 біграми починаються з парних позицій, тому це завжди ab. Біграма одна, її ймовірність 1, отже $H_2 = 0$.

Результати:

4. ЗАЛЕЖНОСТІ МІЖ СИМВОЛАМИ

```
Г (випадкова): частоти символів {'b': 50000, 'a': 50000}
біграми (перетин): {'ba': 25043, 'aa': 24957, 'ab': 25043, 'bb': 24956}
біграми (без перетину): {'ba': 12444, 'aa': 12440, 'ab': 12676, 'bb': 12440}
H1 = 1.000000
H2 (перетин) = 0.999999
H2 (без перетину) = 0.999976

Д (періодична): частоти символів {'a': 50000, 'b': 50000}
біграми (перетин): {'ab': 50000, 'ba': 49999}
біграми (без перетину): {'ab': 50000}
H1 = 1.000000
H2 (перетин) = 0.500000
H2 (без перетину) = 0.000000
```

Прогноз підтвердився

1. H_1 однакове ($1,0 = 1,0$).
2. H_2 різне: 0,9 проти 0,5 (і проти 0 при кроці 2).
3. Менше H_2 у Д.

- для $H^{(10)}$:

[illegible]

Значення $H^{(30)}$:

Лабораторная работа №1

Произвольная часть текста:
вели_себя_другие_люди_для_это

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:
Символ по счету:
Номер эксперимента: 51

Поле ввода символов:

Продолжить

Другой

Неравенство для энтропии:
1.23591495563735< H < 1.92928370768122

Двоичная таблица угаданных символов:
00000000000100000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
00010000000000000000000000000000
01000000000000000000000000000000

Вероятности:

q[1]=0.68
q[2]=0.06
q[3]=0.04
q[4]=0.02
q[5]=0.04
q[6]=0
q[7]=0.02
q[8]=0.04
q[9]=0
q[10]=0
q[11]=0
q[12]=0.02
q[13]=0
q[14]=0
q[15]=0
q[16]=0.04
q[17]=0
q[18]=0.02
q[19]=0.02
q[20]=0
q[21]=0
q[22]=0
q[23]=0
q[24]=0
q[25]=0
q[26]=0
q[27]=0
q[28]=0
q[29]=0
q[30]=0
q[31]=0
q[32]=0

Строка состояния:

Результати в одній порівняльній таблиці:

Оцінка	Отримане значення
H_1 (з пробілами)	4.385508
H_2 (з пробілами)	3.969104
$H^{(10)}$	$1.775882 < H < 2.581119$
$H^{(20)}$	$1.675685 < H < 2.511500$
$H^{(30)}$	$1.235915 < H < 1.929283$

Проаналізовані отримані результати:

1. Чому наведені оцінки ентропії не повинні обов’язково збігатися:

Оцінки H_1 , H_2 та $H^{(N)}$ оцінюють невизначеність джерела на різних рівнях урахування контексту. H_1 , H_2 - це статичні математичні розрахунки безумовних та біграмних ймовірностей для окремих символів чи пар, тоді як $H^{(10)}$, $H^{(20)}$, $H^{(30)}$ відображають експериментальну ентропію (методика

Шеннона або вгадування символу людиною) на основі довгих контекстів у 10, 20 та 30 символів. Довші контексти містять значно більше інформації про структуру мови, що зменшує невизначеність кожного наступного символу.

2. Які статистичні залежності враховуються при визначенні H_1 та H_2 :

H_1 враховує лише **частоту появи окремих символів** алфавіту (одновимірний розподіл ймовірностей $p(i)$). Вона ігнорує будь-який зв'язок між сусідніми літерами та вважає, що символи вибираються незалежно один від одного.

H_2 враховує **двовимірні зв'язки (біграми)** та перехідні ймовірності $p(j|i)$ між двома послідовними символами. Вона описує залежність вибору наступного символу від безпосередньо попереднього.

3. Чому врахування довших залежностей між символами може змінювати оцінку ентропії природної мови:

Природна мова має складну граматичну, морфологічну та синтаксичну структуру. Окремі літери утворюють корені, префікси та закінчення. Послідовності літер складаються у слова, а слова — у сталі звороти та речення. Збільшення довжини контексту надає додаткові обмеження. Наприклад, знаючи лише один попередній символ, важко вгадати наступний, але знаючи контекст із 20–30 символів (наприклад, фрагмент слова чи ціле словосполучення), кількість можливих варіантів наступного символу різко скорочується.

4. Яку тенденцію можна спостерігати при переході від H_1 до оцінок, що враховують дедалі довший контекст.

При збільшенні довжини контексту спостерігається чітка **тенденція до зменшення оцінки ентропії**. Це свідчить про високу надлишковість природної мови: чим більшим контекстом ми володіємо, тим менше нової інформації несе кожен наступний символ, і тим простіше його передбачити.

6. Оцінювання надлишковості джерела

Використовуючи отримані значення ентропії, оцініть надлишковість російського письмового тексту для досліджених моделей джерела.

Загальною формулою надлишковості джерела відкритого тексту є:

$$R = 1 - \frac{H}{H_{\max}}$$

де, $H_{\max} = \log_2 N$, де $N = 33$ (літер алфавіту)

звідки $H_{\max} \approx 5.044$ біт/с

Розрахуємо надлишковість:

$$R_1 = 1 - (4.386 / 5.044) = 1 - 0.87 = 0.13 \text{ (13\%)}$$

$$R_2 = 1 - (3.969 / 5.044) = 1 - 0.787 = 0.213 \text{ (21,3\%)}$$

$$R^{(10)} = 1 - (2.581 / 5.044) = 1 - 0.512 = 0.488 \text{ (48,8\%)}$$

$$R^{(20)} = 1 - (2.512 / 5.044) = 1 - 0.498 = 0.502 \text{ (50,2\%)}$$

$$R^{(30)} = 1 - (1.929 / 5.044) = 1 - 0.382 = 0.618 \text{ (61,8\%)}$$

Порівняйте отримані оцінки та поясніть:

● Як змінюється оцінка надлишковості при врахуванні залежностей між символами:

Початковий рівень R_1 . Коли ми розглядаємо літери як повністю незалежні події, надлишковість є найнижчою (близько 13%). Вона виникає виключно через те, що деякі літери в алфавіті вживаються частіше за інші (наприклад, голосні частіше за "ф" чи "щ")

Врахування коротких залежностей R_2 . Перехід до аналізу пар сусідніх літер (біграм) збільшує надлишковість приблизно до 21,3%. На цьому етапі враховуються найпростіші мовні обмеження (наприклад, що після певних приголосних обов'язково йде голосна).

Врахування довгого контексту $R^{(10)}$, $R^{(20)}$, $R^{(30)}$. Зі збільшенням контексту до 10, 20 та 30 символів оцінка надлишковості стрімко зростає і перевищує 60% ($R^{(30)} \approx 61,8\%$). Довгий контекст охоплює цілі префікси, корені, закінчення та навіть окремі фрази.

Зі збільшенням довжини контексту ми отримуємо все більше інформації про структуру тексту, через що невизначеність щодо наступного символу (ентропія H) постійно зменшується. Оскільки надлишковість R є дзеркальним відображенням ентропії відносно її максимально можливого значення ($H_{\max}$), **зменшення невизначеності автоматично призводить до монотонного зростання надлишковості**. Це означає, що реальний текст містить величезний обсяг дубльованої інформації, яка робить його прогнозованим.

● Чому природна мова має ненульову надлишковість:

Ненульова (і навіть висока, понад 60%) надлишковість природної мови зумовлена її природною структурою:

-Закони граматики та синтаксису. Певні букви, закінчення та слова слідуєть одні за одними за жорсткими правилами.

-Стійкість до завад: Надлишковість забезпечує надійність комунікації. Завдяки їй людина може легко зрозуміти текст із друкарськими помилками, пропущеними буквами чи шумом при усній мові.

-Небайдужий розподіл частот: Літери в алфавіті вживаються з різною частотою, що навіть без урахування контексту дає базову надлишковість $R_1 = 13\%$

● Який зв'язок існує між передбачуваністю наступних символів тексту, ентропією та надлишковістю джерела.

Між цими трьома поняттями існує обернена та пряма залежність.

-Передбачуваність і ентропія: Чим вища передбачуваність наступного символу (завдяки контексту), тим **нижчою є ентропія** H (невизначеність). Кожен новий символ несе менше нової невизначеної інформації.

-Передбачуваність і надлишковість: Чим вища передбачуваність, тим **вищою є надлишковість** R . Збільшення R означає, що повідомлення містить більше структури та повторюваних патернів, які дозволяють легше вгадати наступний елемент.

Реалізація надлишковості для нашої програми:

```
def section6(res_spaces, res_no_spaces):
    print("6. НАДЛИШКОВІСТЬ R = 1 - H / H0")
    cases = (
        ("з пробілами", res_spaces, len(ALPHABET) + 1),
        ("без пробілів", res_no_spaces, len(ALPHABET)),
    )
    for tag, res, m in cases:
        estimates = dict(res)
        estimates.update({f"H({n})": v for n, v in COOLPINK.items() if v is not None})
        print(f"\nТекст {tag} (m = {m}, H0 = {math.log2(m):.6f}):")
        for name, h in estimates.items():
            print(f"    {name:<18} = {h:.4f}    R = {redundancy(h, m):.4f}")
```

6. НАДЛИШКОВІСТЬ $R = 1 - H / H_0$			
Текст з пробілами ($m = 33$, $H_0 = 5.044394$):			
H_1	= 4.3855	R	= 0.1306
H_2 (перетин)	= 3.9691	R	= 0.2132
H_2 (без перетину)	= 3.9689	R	= 0.2132
Текст без пробілів ($m = 32$, $H_0 = 5.000000$):			
H_1	= 4.4690	R	= 0.1062
H_2 (перетин)	= 4.1388	R	= 0.1722
H_2 (без перетину)	= 4.1387	R	= 0.1723

Аналіз результатів

За результатами виконаних експериментів дайте обґрунтовані відповіді на такі питання:

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівноймовірна послідовність символів того самого алфавіту?

У природному тексті літери нерівноймовірні. У 3 пункті $H_1(A) = 4,479$ проти $H_1(B) = 4,9998$ при максимумі $\log_2 32 = 5$, тобто різниця $\approx 0,52$ біта.

Без пробілів літери о, е, а мають частоти 11,3 %, 8,6 %, 7,6 %, а в послідовності В кожна літера має $\approx 3,1$ %. З пробілами _ займає 16,1 %.

Для H_2 розрив ще більший: 4,133 (А) проти 4,996 (В), бо в тексті додатково є залежності між сусідніми літерами, а у В їх нема.

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

H_2 враховує залежність наступного символу від попереднього (розподіл пар). З пробілами $H_2 = 3,969 < H_1 = 4,386$ (на 0,42 біта), без пробілів $4,139 < 4,469$ (на 0,33). Це видно й у топі біграм: о_, е_, и_, _п, _н, «то», «ов», «ко» трапляються значно частіше, ніж було б за незалежних символів. У випадковій В $H_2 \approx H_1$, бо залежностей нема.

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ? Наведіть приклад із виконаних експериментів.

Так, це пара Г і Д. В обох по 50 000 символів а і b, тому $H_1 = 1,000000$. Проте $H_2 = 0,999999$ у Г і $0,500000$ у Д (при кроці 2: 0,999976 проти 0). Частоти однакові, порядок різний.

4. Як вилучення пробілів вплинуло на отримані значення ентропії?
Поясніть отриманий результат.

H_1 зросла з 4,386 до 4,469 (+0,083), H_2 з 3,969 до 4,139 (+0,170).
Надлишковість зменшилась: за H_1 з 0,131 до 0,106, за H_2 з 0,213 до 0,172.
Причина була в тому, що пробіл був найчастішим символом (16,1 %) і робив розподіл нерівномірнішим, він дуже передбачуваний: усі п'ять найчастіших біграм з пробілом містять його. Тому H_2 зросла вдвічі сильніше за H_1 : зникли найпередбачуваніші пари. Ще змінилось H_0 (5,044 $\rightarrow$ 5,0).

5. Чому оцінки H_2 , отримані за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Різниця мізерна: 3,969104 проти 3,968870 (0,00023) з пробілами і 4,138761 проти 4,138674 (0,00009) без. Спосіб без перетину має вдвічі менше біграм ($\approx 444\,820$ проти $889\,640$ з пробілами), тож частоти менш стабільні, також він бере пари лише з парних позицій, тому залежить від фази.

Найкраще це видно на Д: 0,5 проти 0. Більше даних використовує спосіб з перетином.

6. Чому значення H_1 , H_2 , $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ відрізняються?

Вони враховують різну довжину контексту: 0, 1, 9, 19 і 29 попередніх символів. Чим більше контексту, тим менша невизначеність: $4,39 \rightarrow 3,97 \rightarrow \leq 2,58 \rightarrow \leq 2,51 \rightarrow \leq 1,93$. Є й різниця методів. H_1 та H_2 рахуються за частотами на великому тексті, а $H(n)$ отримані вгадуванням і дають лише межі (наприклад, $1,776 < H^{(10)} < 2,581$). Верхня межа завищена, бо вгадувальник не використовує всіх закономірностей мови.

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?

4 пункт: H_1 однакове, а H_2 різне (1,0 проти 0,5), тобто ефект дає лише порядок символів. Для реальної мови це підтверджують $H_2 < H_1$ і різке падіння до $H^{(10)} \leq 2,58$.

8. Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації?

Ентропія є теоретичною межею стиснення без втрат, а R показує, яка частка ємності алфавіту не використана. Відносно 5,04 біт/символ модель H_1 дає $\approx 13\%$ економії, $H_2 \approx 21\%$, а з довгим контекстом (верхня межа $H^{(30)} = 1,93$) $\approx 62\%$ і більше. Крайні випадки: В ($H \approx 5,0$, $R \approx 0$) не стискається, а Д ($H \rightarrow 0$) стискається майже повністю.

Висновки

У ході роботи ми експериментально оцінили ентропію на символ для російського текстового джерела (текст «Мертвые души», понад 1 МБ) за кількома моделями і порівняли їх між собою. Для тексту з пробілами, який містить 889 641 символ, отримано $H_1 = 4,386$ біт і $H_2 = 3,969$ біт, тоді як для тексту без пробілів (746 137 символів) $H_1 = 4,469$ біт і $H_2 = 4,139$ біт. В обох випадках ентропія помітно менша за максимальне значення H_0 (5,044 біт для 33 символів і 5,0 біт для 32 літер), а H_2 менша за H_1 . Це означає, що літери в тексті вживаються з різною частотою, а сусідні літери пов'язані між собою. Значення H_2 , отримані для біграм із перетином і без перетину, майже збіглися (різниця 0,0002 біта для тексту з пробілами і 0,0001 біта для тексту без пробілів), що пояснюється великим обсягом тексту. Разом із тим спосіб із перетином використовує вдвічі більше біграм і тому є надійнішим. Вилучення пробілів збільшило і H_1 , і H_2 , причому H_2 зросла помітніше, оскільки пробіл був найчастішим символом (16,1 %) і входив до найпередбачуваніших біграм.

Моделльні експерименти підтвердили теоретичні очікування. У 3 пункті послідовності розташувалися в порядку Б ($H_1 = 0$), А (4,479) і В (4,9998), тобто чим рівномірніший розподіл символів, тим більша ентропія. У розділі 4 послідовності Г і Д мали однакове $H_1 = 1$ біт, проте H_2 становило 0,999999 для випадкової послідовності і 0,5 для періодичної, а при біграмах без перетину для періодичної воно впало до нуля. Цей експеримент наочно показав, що модель незалежних символів не бачить порядку, а модель біграм його враховує.

За допомогою CoolPinkProgram отримано інтервальні оцінки: $1,776 < H^{(10)} < 2,581$, $1,676 < H^{(20)} < 2,512$ і $1,236 < H^{(30)} < 1,929$. Вони суттєво менші за H_1 і H_2 , і загалом ентропія зменшується зі збільшенням довжини контексту, хоча інтервали для $n = 10$ і $n = 20$ значною мірою перекриваються. Це відображає те, що на довших відстанях мова підпорядкована морфології, граматиці та стійким зворотам, а тому наступний символ стає значно

передбачуванішим. Слід пам'ятати, що ці оцінки є межами за нерівністю і є завищеними, бо людина не використовує всіх закономірностей мови.

Відповідно змінюється й надлишковість джерела. Вона становить близько 13 % за моделлю незалежних символів, приблизно 21 % за біграмною моделлю і, за верхніми межами оцінок $H^{(n)}$, від 49 до 62 % при контексті 10–30 символів. Отже, значну частину російського тексту складають передбачувані елементи, і саме це робить принципово можливим його стиснення без втрати інформації. Для випадкової рівноймовірної послідовності надлишковість близька до нуля, і стиснути її не вдається. Таким чином, робота показала, що ентропія та надлишковість є двома сторонами одного явища: чим краще модель враховує залежності між символами, тим менша оцінка ентропії і тим більша оцінка надлишковості джерела.