

Міністерство освіти і науки України
Національний технічний університет України «Київський політехнічний інститут імені
Ігоря Сікорського»

Навчально-науковий фізико-технічний інститут
Кафедра інформаційної безпеки

КОМП'ЮТЕРНИЙ ПРАКТИКУМ №1

З дисципліни

«КРИПТОГРАФІЯ»

**«Експериментальна оцінка ентропії на символ джерела відкритого
тексту»**

Виконали:

Студенти 3-го курсу, групи ФБ-43

Горбонос О. та Дрепіна А.

Перевірила: Селюх Поліна Валентинівна

Київ 2026

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

1. Підготовка тексту

1.1. Використаний текст

Для роботи обрано роман Л. М. Толстого «Анна Каренина» (російською мовою), електронна версія з бібліотеки Мошкова (az.lib.ru). Взято основний текст роману без епіграфа та службових елементів сайту (навігація, заголовки сторінки). Обсяг після обробки значно перевищує вимогу в 1 МБ (таблиця 1).

Таблиця 1 — Параметри тексту після попередньої обробки

Версія тексту	Довжина, символів	Розмір файлу (UTF-8)	Алфавіт, m	$H_0 = \log_2 m$, біт
З пробілами	1 606 238	≈ 2,94 МБ	32	5,0000
Без пробілів	1 336 164	≈ 2,67 МБ	31	4,9542

1.2. Алфавіт і правила попередньої обробки

Алфавіт складається з 31 літери російської абетки (а–я без «ё» та «ъ») і пробілу, разом 32 символи. Саме такий алфавіт використовує програма CoolPinkProgram (у її полі «Использованные буквы» відображаються 31 літера та символ «_» для пробілу, а список імовірностей містить $q[1] \dots q[32]$), тому оцінки H_1 , H_2 і $H^{(n)}$ порівнянні між собою.

Правила попередньої обробки, реалізовані в програмі:

- усі літери приводяться до нижнього регістру;
- літера «ё» замінюється на «е», літера «ъ» на «ь»;
- усі символи, що не належать до алфавіту (цифри, розділові знаки, латиниця, переноси рядків), замінюються пробілами;
- послідовності пробілів згортаються в один пробіл, пробіли на початку й у кінці тексту видаляються;
- для обчислень без пробілів з нормалізованого тексту видаляються всі пробіли.

2. Розрахунок статистичних характеристик тексту

2.1. Програмна реалізація

Програми написано мовою Python 3 і запущено в Google Colab. Реалізація складається з трьох файлів: `prepare_text.py` (завантаження та нормалізація тексту, створення двох його версій), `entropy_stats.py` (підрахунок частот символів і біграм, обчислення H_1 та H_2 , збереження таблиць частот у CSV) та `experiments_3_4.py` (формування послідовностей А–Д і обчислення їхніх ентропій).

Ентропія обчислюється за формулою $H = -\sum p_i \log_2 p_i$, де p_i — відносна частота елемента. Для біграм, що перетинаються, вікно з двох символів зсувається на один символ, для біграм, що не перетинаються, — на два (при непарній довжині тексту останній символ відкидається). Ентропія на символ для біграм: $H_2 = H(\text{біграм}) / 2$, відповідно до $H_n = H(x_1, \dots, x_n) / n$. Випадкові послідовності генеруються з фіксованим початковим значенням генератора (`seed = 42`) для відтворюваності.

2.2. Частоти символів і біграм

У таблицях 2 і 3 наведено частоти символів та 20 найчастіших біграм, що перетинаються. Символ «_» позначає пробіл. Повні таблиці частот (усі символи та всі біграми для чотирьох конфігурацій) збережено у файлах CSV у каталозі results репозиторію.

Таблиця 2 — Частоти символів (з пробілами та без пробілів)

№	Символ	Кількість	p	Символ	Кількість	p
1	_	270 074	0,1681	о	154 105	0,1153
2	о	154 105	0,0959	е	117 352	0,0878
3	е	117 352	0,0731	а	111 173	0,0832
4	а	111 173	0,0692	н	92 646	0,0693
5	н	92 646	0,0577	и	88 213	0,0660
6	и	88 213	0,0549	т	80 084	0,0599
7	т	80 084	0,0499	с	70 523	0,0528
8	с	70 523	0,0439	л	67 540	0,0505
9	л	67 540	0,0420	в	62 889	0,0471
10	в	62 889	0,0392	р	52 638	0,0394
11	р	52 638	0,0328	к	45 849	0,0343
12	к	45 849	0,0285	д	39 781	0,0298
13	д	39 781	0,0248	м	38 343	0,0287
14	м	38 343	0,0239	у	36 460	0,0273
15	у	36 460	0,0227	п	32 259	0,0241
16	п	32 259	0,0201	я	29 028	0,0217
17	я	29 028	0,0181	ь	27 179	0,0203
18	ь	27 179	0,0169	ы	24 778	0,0185
19	ы	24 778	0,0154	г	24 306	0,0182
20	г	24 306	0,0151	б	23 525	0,0176
21	б	23 525	0,0146	ч	22 820	0,0171
22	ч	22 820	0,0142	з	21 911	0,0164
23	з	21 911	0,0136	ж	15 352	0,0115
24	ж	15 352	0,0096	й	13 750	0,0103
25	й	13 750	0,0086	ш	11 631	0,0087
26	ш	11 631	0,0072	х	10 235	0,0077
27	х	10 235	0,0064	ю	8 417	0,0063
28	ю	8 417	0,0052	э	4 765	0,0036
29	э	4 765	0,0030	щ	3 797	0,0028
30	щ	3 797	0,0024	ц	3 469	0,0026
31	ц	3 469	0,0022	ф	1 346	0,0010
32	ф	1 346	0,0008	—	—	—

Примітка: ліворуч — текст з пробілами (N = 1 606 238), праворуч — без пробілів (N = 1 336 164).

Таблиця 3 — 20 найчастіших біграм, що перетинаються (з пробілами та без пробілів)

№	Біграма	Кількість	p	Біграма	Кількість	p
1	о_	39 069	0,0243	то	23 336	0,0175
2	е_	30 564	0,0190	на	17 949	0,0134
3	а_	30 239	0,0188	он	17 392	0,0130
4	и_	29 249	0,0182	ст	16 680	0,0125
5	_н	26 712	0,0166	ал	16 238	0,0122

№	Біграма	Кількість	p	Біграма	Кількість	p
6	_с	26 001	0,0162	не	16 132	0,0121
7	_в	23 648	0,0147	но	15 898	0,0119
8	то	22 912	0,0143	ов	15 124	0,0113
9	_п	22 569	0,0141	ен	13 776	0,0103
10	_о	21 934	0,0137	го	13 406	0,0100
11	я_	17 968	0,0112	по	13 097	0,0098
12	_и	17 827	0,0111	ко	12 953	0,0097
13	на	17 456	0,0109	ос	12 691	0,0095
14	ь_	17 034	0,0106	от	12 624	0,0094
15	ст	16 285	0,0101	ни	12 543	0,0094
16	не	15 990	0,0100	ла	12 524	0,0094
17	ал	15 582	0,0097	ка	12 472	0,0093
18	но	15 410	0,0096	во	11 770	0,0088
19	_к	14 532	0,0090	ро	10 889	0,0081
20	он	13 486	0,0084	ло	10 845	0,0081

2.3. П'ять найчастіших символів і біграм

Таблиця 4 — П'ять найчастіших символів (кількість, ймовірність)

Версія тексту	Топ-5 символів
З пробілами	«_»: 270 074 (0,1681); «о»: 154 105 (0,0959); «е»: 117 352 (0,0731); «а»: 111 173 (0,0692); «н»: 92 646 (0,0577)
Без пробілів	«о»: 154 105 (0,1153); «е»: 117 352 (0,0878); «а»: 111 173 (0,0832); «н»: 92 646 (0,0693); «и»: 88 213 (0,0660)

Таблиця 5 — П'ять найчастіших біграм (кількість)

Версія тексту	Тип біграм	Топ-5 біграм
З пробілами	перетинні	«о_»: 39 069; «е_»: 30 564; «а_»: 30 239; «и_»: 29 249; «_н»: 26 712
З пробілами	неперетинні	«о_»: 19 607; «е_»: 15 189; «а_»: 15 017; «и_»: 14 651; «_н»: 13 451
Без пробілів	перетинні	«то»: 23 336; «на»: 17 949; «он»: 17 392; «ст»: 16 680; «ал»: 16 238
Без пробілів	неперетинні	«то»: 11 720; «на»: 8 921; «он»: 8 670; «ст»: 8 355; «ал»: 8 280

2.4. Значення H_1 та H_2

Таблиця 6 — Ентропія на символ для тексту «Анна Каренина», біт/символ

Версія тексту	Біграм (перетинні / неперетинні)	H_1	H_2 (перетинні)	H_2 (неперетинні)	Різниця H_2
З пробілами	1 606 237 / 803 119	4,3450	3,9364	3,9365	0,0001
Без пробілів	1 336 163 / 668 082	4,4377	4,1183	4,1180	0,0003

Порівняння біграм, що перетинаються та не перетинаються. Значення H_2 для двох способів майже збігаються: різниця становить 0,0001 біт для тексту з пробілами та 0,0003 біт без пробілів, що на три порядки менше за різницю між H_1 і H_2 (близько 0,4 біт). Обидва способи оцінюють одну й ту саму величину для стаціонарного джерела, тому суттєвих розбіжностей не очікується. Відмінність зумовлена обсягом вибірки: перетинний спосіб використовує кожну пару сусідніх символів (1 606 237 біграм), а неперетинний —

лише кожен другу (803 119 біграм), тобто приблизно вдвічі менше статистичних даних. Тому перетинний спосіб використовує більше даних і дає стійкішу оцінку, хоча сусідні біграми в ньому залежні між собою. Для тексту такого обсягу (понад 10^6 символів при $32^2 = 1024$ можливих біграмах) вплив розміру вибірки мізерний; для коротких послідовностей він помітніший (див. розділ 4).

3. Дослідження впливу розподілу символів на ентропію

Сформовано три послідовності однакової довжини 200 000 символів: **А** — перші 200 000 символів природного тексту (з пробілами); **Б** — повторення одного символу (найчастішого в тексті, пробілу); **В** — випадкова послідовність символів того самого алфавіту (32 символи), у якій кожен символ обирається з однаковою ймовірністю.

Прогноз (до обчислень): порядок зростання H_1 — **Б** < **А** < **В**. Для **Б** один символ має ймовірність 1, невизначеності немає, отже $H_1 = 0$. Для **В** усі 32 символи рівноймовірні, тому H_1 має бути близьким до максимально можливого значення $\log_2 32 = 5$ біт (трохи меншим через скінченну довжину вибірки). Для **А** букви зустрічаються нерівномірно (пробіл та «о» значно частіші за «ф» чи «щ»), тому ентропія лежить між цими значеннями, близько 4,3–4,4 біт.

Таблиця 7 — H_1 для послідовностей А, Б, В (довжина 200 000)

Послідовність	Опис	Різних символів	H_1 , біт/символ
Б	один символ (пробіл)	1	0,0000
А	фрагмент природного тексту	32	4,3483
В	випадкова, рівноймовірна	32	4,9999

Порівняння з прогнозом. Отриманий порядок **Б** (0) < **А** (4,3483) < **В** (4,9999) збігся з прогнозом. Значення для **В** трохи менше за $\log_2 32 = 5$ через скінченність вибірки, а $H_1(\text{А}) = 4,3483$ близьке до H_1 усього тексту (4,3450). **Висновок:** ентропія на символ, обчислена за одновимірним розподілом, визначається лише ступенем його рівномірності. Вироджений розподіл (один символ з ймовірністю 1) дає нульову ентропію, рівномірний — максимальну ($\log_2 m$), а нерівномірний розподіл природного тексту — проміжну. Нерівномірність розподілу зменшує ентропію відносно $\log_2 m$.

4. Дослідження залежностей між символами

Сформовано дві послідовності довжини 200 000 на алфавіті {a, b}: **Д** — строго періодична abab...; **Г** — та сама послідовність, випадково перемішана (по 100 000 символів кожного виду, тому частоти символів у **Г** та **Д** збігаються точно).

Прогноз (до обчислень):

- H_1 для **Г** і **Д** суттєво не відрізняється: частоти символів однакові, а H_1 залежить лише від них.
- H_2 для **Г** і **Д** суттєво відрізняється, бо H_2 враховує сусідні символи, а їхній порядок у послідовностях принципово різний.
- Менше значення H_2 очікується для **Д**: періодичність робить наступний символ повністю передбачуваним за попереднім.
- Для **Д** значення H_2 для біграм, що перетинаються та не перетинаються, різнитимуться (для неперетинних усі біграми однакові, «ab», і вони мають дати 0, для перетинних біграм «ab» і «ba» — приблизно 0,5), для **Г** — практично збігатимуться.

Таблиця 8 — H_1 та H_2 для послідовностей Γ і D , біт/символ

Послідовність	H_1	H_2 (перетинні)	H_2 (неперетинні)
Γ (випадковий порядок)	1,0000	1,0000	1,0000
D (періодична abab...)	1,0000	0,5000	0,0000

Додатково виконано той самий експеримент на алфавіті з 31 літери: D_{31} — 31 літера, що циклічно повторюється (період 31), Γ_{31} — та сама послідовність, випадково перемішана (довжина $199\,981 = 6451 \times 31$).

Таблиця 9 — Додатковий експеримент (алфавіт з 31 літери), біт/символ

Послідовність	H_1	H_2 (перетинні)	H_2 (неперетинні)
Γ_{31} (випадковий порядок)	4,9542	4,9525	4,9505
D_{31} (циклічний період 31)	4,9542	2,4771	2,4771

Порівняння з прогнозом та пояснення. Прогноз підтвердився: $H_1(\Gamma) = H_1(D) = 1,0000$, тоді як $H_2(\Gamma) = 1,0000$, а $H_2(D) = 0,5000$ (перетинні) і $0,0000$ (неперетинні). Тексти з однаковими частотами окремих символів мають однакове H_1 , бо воно не залежить від порядку символів. У Γ чотири біграми «aa», «ab», «ba», «bb» зустрічаються приблизно з ймовірністю $1/4$, тому ентропія біграм дорівнює 2 біт і $H_2 = 1$. У D існують лише біграми «ab» та «ba» (по $1/2$), ентропія біграм — 1 біт і $H_2 = 0,5$. Модель біграм на відміну від моделі незалежних символів враховує спільний розподіл сусідніх символів і тому виявляє структурну передбачуваність джерела, недоступну для H_1 .

Слід зазначити, що навіть для повністю детермінованої послідовності D значення H_2 для біграм, що перетинаються, дорівнює $0,5$, а не 0 . Причина в тому, що H_2 визначається як ентропія біграм, поділена на 2: $H_2 = (H_1 + H(x_2 | x_1)) / 2$, а умовна ентропія $H(x_2 | x_1)$ для D дорівнює 0 , тобто $(1 + 0) / 2 = 0,5$. Різниця між перетинними та неперетинними біграмами для D ($0,5$ проти 0) зумовлена парністю періоду: при періоді 2 неперетинні біграми завжди починаються з «a». У додатковому експерименті з непарним періодом 31 неперетинні біграми також пробігають усі можливі пари, тому обидва способи дають однаковий результат $\log_2 31 / 2 = 2,4771$. Для Γ_{31} різниця між $4,9525$ та $4,9505$ невелика і пояснюється скінченним обсягом вибірки.

5. Експериментальна оцінка ентропії джерела

5.1. Методика

Оцінки $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ отримано за допомогою програми CoolPinkProgram. У кожному експерименті програма показує випадковий уривок російського тексту з $n - 1$ символів, а експериментатор вводить літери по одній, доки не вгадає наступну літеру; програма фіксує номер спроби i , з якої літеру вгадано, і накопичує значення $q_i^{(n)}$ — частку експериментів, у яких літеру вгадано з i -ї спроби. За цими значеннями програма обчислює межі за нерівністю з методички:

$$\sum i \cdot (q_i - q_{i+1}) \cdot \log_2 i + m \cdot q_m \cdot \log_2 m \leq H^{(n)} \leq -\sum q_i \cdot \log_2 q_i,$$

де $m = 32$ — розмір алфавіту. Для кожного значення n виконано не менше 50 експериментів (таблиця 10). Лічильник «Номер експерименту» у вікні програми показує номер наступного експерименту, тому фактично виконано на один експеримент менше, ніж на скріншотах. Правильність обчислення програми перевірено: перерахунок меж за формулою з отриманих значень q дав ті самі числа. Текст, з якого програма формує уривки, відрізняється від використаного нами роману.

Таблица 10 — Результаты экспериментов у CoolPinkProgram

n	Экспериментів	q ₁	q ₂	q ₃	q ₄	q ₅	Нижня межа	Верхня межа
10	54	0,5741	0,1481	0,0370	0,0556	0,0185	1,4313	2,1791
20	54	0,6481	0,1296	0,0370	0,0370	0,0185	1,2630	1,9924
30	53	0,5660	0,1887	0,0566	0,0189	0,0189	1,4608	2,1962

Розподіл кількості експериментів за номером спроби (номер спроби: кількість вгадувань): n = 10 — 1: 31, 2: 8, 3: 2, 4: 3, 5: 1, 8: 2, 9: 2, 10: 1, 11: 3, 17: 1; n = 20 — 1: 35, 2: 7, 3: 2, 4: 2, 5: 1, 11: 1, 13: 1, 15: 1, 17: 1, 20: 1, 23: 1, 28: 1; n = 30 — 1: 30, 2: 10, 3: 3, 4: 1, 5: 1, 8: 2, 12: 1, 14: 1, 15: 1, 19: 1, 26: 1, 31: 1.




Рисунок 1 — CoolPinkProgram, n = 10




Рисунок 2 — CoolPinkProgram, n = 20




Рисунок 3 — CoolPinkProgram, $n = 30$

5.2. Порівняльна таблиця оцінок

Таблиця 11 — Порівняння оцінок ентропії, біт/символ

Оцінка	Отримане значення
H_1	4,3450 (текст з пробілами)
H_2	3,9364 (біграми, що перетинаються, текст з пробілами)
$H^{(10)}$	$1,4313 < H < 2,1791$
$H^{(20)}$	$1,2630 < H < 1,9924$
$H^{(30)}$	$1,4608 < H < 2,1962$

5.3. Аналіз отриманих результатів

1. Чому оцінки не повинні обов'язково збігатися. Це оцінки різних моделей джерела. H_1 відповідає моделі незалежних символів, H_2 враховує залежність від одного попереднього символу, а $H^{(n)}$ відповідає передбаченню людини за 9, 19 та 29 попередніми символами. Крім того, H_1 і H_2 обчислені за 1,6 млн символів нашого роману (точні статистичні оцінки), тоді як $H^{(n)}$ — інтервальні оцінки за нерівністю з методички за кількома десятками експериментів на тексті програми, до того ж завищені, бо експериментатор не може врахувати всіх закономірностей мови.

2. Які залежності враховують H_1 та H_2 . H_1 враховує лише одновимірний розподіл частот окремих символів, без урахування їхнього положення. H_2 додатково враховує двовимірний розподіл, тобто залежність символу від сусіднього. У нашому тексті це видно за біграмами: найчастіші пари з пробілами «о_», «е_», «а_», «и_» показують, що слова часто закінчуються на ці літери, а без пробілів провідними є пари «то», «на», «он», «ст», «ал».

3. Чому врахування довших залежностей змінює оцінку. Контекст із 9–29 символів охоплює ціле слово або кілька слів, і людина, знаючи корені слів, закінчення, лексику та граматику, здатна вгадати наступну літеру. У наших експериментах наступну літеру було вгадано з першої спроби у 57–65% випадків ($q_1 = 0,5741; 0,6481; 0,5660$), тоді як для моделі H_1 найімовірніший символ (пробіл) має ймовірність лише 0,1681. Це різко зменшує невизначеність наступного символу.

4. Тенденція при переході від H_1 до довших контекстів. Спостерігається різке зниження: $H_1 = 4,3450 > H_2 = 3,9364 \gg$ верхніх меж $H^{(n)}$ (2,1791; 1,9924; 2,1962). Проте між $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ монотонного зниження не спостерігається: найнижчі межі отримано для $n = 20$, а для $n = 30$ вони знову вищі. Така різниця в межах статистичної похибки: при кількості експериментів близько 54 стандартна похибка частки $q_1 \approx \sqrt{(0,6 \cdot 0,4 / 54)} \approx 0,07$, тобто порівнянна з розбіжністю між серіями (0,57; 0,65; 0,57). Тому надійно можна стверджувати лише, що врахування довгого контексту суттєво зменшує ентропію порівняно з H_1 і H_2 , а додаткове збільшення контексту з 10 до 30 символів на нашій вибірці суттєвого зниження не дало.

6. Оцінювання надлишковості джерела

Надлишковість обчислюється за формулою $R = 1 - H / H_0$, де $H_0 = \log_2 m$ — максимальна ентропія алфавіту: для тексту з пробілами $H_0 = \log_2 32 = 5$ біт, без пробілів $H_0 = \log_2 31 \approx 4,9542$ біт. Для $H^{(n)}$ наведено значення за верхньою та нижньою межами.

Таблиця 12 — Надлишковість джерела для різних моделей

Модель	H , біт/символ	H_0 , біт	R
H_1 , з пробілами	4,3450	5,0000	0,1310 (13,1%)
H_2 , з пробілами	3,9364	5,0000	0,2127 (21,3%)
H_1 , без пробілів	4,4377	4,9542	0,1042 (10,4%)
H_2 , без пробілів	4,1183	4,9542	0,1687 (16,9%)
$H^{(10)}$, верхня / нижня межа	2,1791 / 1,4313	5,0000	0,5642 / 0,7137
$H^{(20)}$, верхня / нижня межа	1,9924 / 1,2630	5,0000	0,6015 / 0,7474
$H^{(30)}$, верхня / нижня межа	2,1962 / 1,4608	5,0000	0,5608 / 0,7078

Як змінюється оцінка надлишковості при врахуванні залежностей. Надлишковість суттєво зростає: від 13,1% для моделі незалежних символів (лише нерівномірність частот) до 21,3% для біграм, а за оцінками $H^{(n)}$ — щонайменше 56% (за верхніми межами) і до 70–75% (за нижніми). Оскільки оцінка $H^{(n)}$ завищена, надлишковість за верхньою межею слід вважати обережною оцінкою знизу.

Чому природна мова має ненульову надлишковість. Не всі послідовності літер є допустимими словами, не всі поєднання слів утворюють речення, а літери та біграми мають сильно різну частоту (наприклад, пробіл — 16,8%, а «ф» — лише 0,08%). Ця передбачуваність зменшує ентропію відносно $\log_2 m$ і забезпечує завадостійкість мови: текст з помилками або пропусками можна відновити.

Зв'язок передбачуваності, ентропії та надлишковості. Чим краще передбачається наступний символ за контекстом, тим менша ентропія H і тим більша надлишковість $R = 1 - H / H_0$. Це узгоджується з експериментом: імовірність вгадати літеру з першої спроби зростає з 0,17 для найчастішого символу (модель H_1) до 0,57–0,65 при контексті 9–29 символів, а надлишковість — з 13% до понад 56%.

Аналіз результатів

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівномірна послідовність того самого алфавіту? Символи природного тексту з'являються з різною частотою: пробіл має ймовірність 0,1681, «о» — 0,0959, а «ф» — лише 0,0008, тоді як у рівномірній послідовності кожен із 32 символів має ймовірність $1/32 \approx 0,0313$. Чим нерівномірніший розподіл, тим менша невизначеність. Це підтвердив експеримент розділу 3: $H_1(A) = 4,3483$ біт, що менше за $H_1(B) = 4,9999$ біт. Крім того, залежності між символами ще більше знижують ентропію ($H_2 = 3,9364$).

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ? H_2 враховує спільний розподіл сусідніх символів, тобто залежність наступного символу від попереднього. Зв'язок з взаємною інформацією: $H_1 - H_2 \approx I(x_1; x_2) / 2$, тобто взаємна інформація між сусідніми символами у нашому тексті становить приблизно $2 \cdot (4,3450 - 3,9364) \approx 0,82$ біт. Умовна ентропія наступного символу за попереднім $H(x_2 | x_1) \approx 2H_2 - H_1 \approx 3,53$ біт.

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ? Так. У розділі 4 послідовності Г (випадковий порядок) і Д (періодична) мають однакові частоти символів, тому $H_1(\Gamma) = H_1(D) = 1,0000$, але $H_2(\Gamma) = 1,0000$, а $H_2(D) = 0,5000$ (перетинні біграми) і $0,0000$ (неперетинні). У додатковому експерименті з алфавітом з 31 літери маємо $H_1 = 4,9542$ в обох послідовностях, проте $H_2(\Gamma_{31}) = 4,9525$ та $H_2(D_{31}) = 2,4771$.

4. Як вилучення пробілів вплинуло на отримані значення ентропії? Ентропія зросла: H_1 з 4,3450 до 4,4377 біт, H_2 з 3,9364 до 4,1183 біт. Пробіл — найчастіший символ (16,8%), його наявність робить розподіл нерівномірнішим і зменшує H_1 ; крім того, пробіл сильно пов'язаний із сусідніми літерами (найчастіші біграми «о_», «е_», «а_», «и_»), тому він додає передбачуваності. Без пробілів розподіл літер вирівнюється (найчастіша літера «о» має 11,5%), а межі слів зникають. При цьому надлишковість знизилася (R_1 з 13,1% до 10,4%, R_2 з 21,3% до 16,9%).

5. Чому оцінки H_2 для біграм, що перетинаються та не перетинаються, можуть дещо відрізнятися? Обидва способи оцінюють одну й ту саму величину за різною вибіркою: перетинний використовує близько 1 606 237 біграм, неперетинний — вдвічі менше (803 119), тому його оцінка має більший статистичний розкид. У наших результатах різниця мізерна (0,0001 і 0,0003 біт). Для послідовностей із жорсткою періодичністю різниця може бути суттєвою (Д: 0,5 і 0), бо вибір зсуву впливає на те, які біграми потрапляють до вибірки.

6. Чому значення H_1 , H_2 , $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ відрізняються? Вони відповідають моделям з різною довжиною врахованого контексту: 0, 1, 9, 19 та 29 попередніх символів. Чим довший контекст, тим більше закономірностей мови (закінчення, корені, слова) враховано і тим менша невизначеність наступного символу: $4,3450 \rightarrow 3,9364 \rightarrow$ менше 2,2. Різниця між $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ лежить у межах похибки вибірки (близько 54 експериментів).

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами? Експеримент розділу 4 (Г проти Д): при однакових частотах символів ($H_1 = 1,0000$) значення H_2 різняться удвічі (1,0000 проти 0,5000). Для реального тексту залежності найяскравіше проявляються в експериментах з CoolPinkProgram: наступну літеру вгадано з першої спроби в 57–65% випадків, тоді як за моделлю незалежних символів найкраща здогадка (пробіл) правильна лише у 16,8% випадків.

8. Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації? Ентропія на символ є нижньою межею середньої кількості біт на символ при кодуванні без втрат. Рівномірний код для 32 символів потребує 5 біт на символ. Модель H_1 дозволяє скоротити це до 4,35 біт (стиснення в 1,15 раза), модель біграм — до 3,94 біт (в 1,27 раза), а врахування довгого контексту ($H^{(n)} \leq 2,2$ біт) — потенційно щонайменше у 2,3 раза ($5 / 2,2 \approx 2,3$). Надлишковість 56% і більше означає, що більше половини символів природного тексту можна не передавати без втрати змісту. Це теоретична межа, яку на практиці алгоритми стиснення лише наближають.

Висновки

У роботі експериментально досліджено ентропію на символ джерела відкритого тексту (роман «Анна Каренина», алфавіт з 31 літери та пробілу) та оцінено його надлишковість.

- Ентропія залежить від розподілу символів: для послідовностей довжиною 200 000 отримано $H_1 = 0$ для повторення одного символу, 4,3483 біт для природного тексту та 4,9999 біт для рівномірної випадкової послідовності (максимум $\log_2 32 = 5$ біт).
- Для тексту з пробілами $H_1 = 4,3450$, $H_2 = 3,9364$ біт/символ, без пробілів $H_1 = 4,4377$, $H_2 = 4,1183$ біт/символ. Вилучення пробілів збільшує ентропію та зменшує надлишковість. Оцінки H_2 для біграм, що перетинаються та не перетинаються, практично збігаються (різниця до 0,0003 біт), перетинний спосіб використовує вдвічі більше даних.
- Експеримент з послідовностями Г і Д показав, що однакові частоти символів ($H_1 = 1$) можуть відповідати різним H_2 (1,0 для випадкової та 0,5 для періодичної послідовності): H_2 враховує залежності між сусідніми символами, недоступні H_1 .
- За допомогою CoolPinkProgram (не менше 50 експериментів для кожного n) отримано оцінки $1,4313 < H^{(10)} < 2,1791$, $1,2630 < H^{(20)} < 1,9924$ та $1,4608 < H^{(30)} < 2,1962$ біт/символ. Ці значення значно менші за H_1 та H_2 , тобто врахування довгого контексту суттєво зменшує невизначеність. Між різними n при такому обсязі вибірки відмінності в межах статистичної похибки.
- Надлишковість зростає від 13,1% (H_1) через 21,3% (H_2) до щонайменше 56% (за верхніми межами $H^{(n)}$). Це означає, що природний текст має високу передбачуваність, що забезпечує завадостійкість мови та теоретичну можливість стиснення тексту без втрати інформації щонайменше вдвічі.