Криптографія. Комп'ютерний практикум №3

Криптоаналіз афінної біграмної підстановки

Коротка Ксенія та Тимчак Анастасія, ФБ-43 · Варіант 4

Мета роботи

Набуття навичок частотного аналізу на прикладі розкриття моноалфавітної підстановки; опанування прийомами роботи в модулярній арифметиці.

Постановка задачі та вхідні дані

Шифртекст варіанта 4 отримано афінною підстановкою біграм: відкритий текст розбивається на біграми, що не перетинаються, кожна біграма (x_1, x_2) переводиться в число $X = x_1 \cdot m + x_2$, а шифрується за правилом $Y = (aX + b) \bmod m^2$. Потрібно лише за шифртекстом знайти ключ (a, b) і відкритий текст.

- **Алфавіт:** 31 літера російської мови, «ё» → «е», «ъ» → «ь»; порядок `абвгдежзийклмнопрстуфхцчшщьыэюя` (а = 0, …, я = 30), $m = 31$, $m^2 = 961$.
- **Шифртекст варіанта 4** (`variants/04.txt`): 5846 літер, 2923 біграми.
- **Найчастіші біграми мови** (з методичних вказівок): ст, но, то, на, ен. Перевірка на корпусі з першого практикуму (біграми без перетину) дала то, на, он, ст, не — чотири з п'яти збігаються з точністю до порядку, тож для атаки взято список з методички.

Програмна реалізація

Програма `lab3.py` (Python, лише стандартна бібліотека) містить:

- `egcd` — розширений алгоритм Евкліда: $d = \gcd(a, b) = u \cdot a + v \cdot b$;
- `inverse` — обернений елемент $a^{-1} \bmod n$ (або відсутність, якщо $\gcd(a, n) \neq 1$);
- `solve_linear` — усі розв'язки порівняння $a \cdot x \equiv b \pmod n$: один при $\gcd = 1$, жодного або рівно d при $\gcd = d > 1$;
- `bigrams` — частоти біграм без перетину (як у першому практикумі);
- `encrypt` / `decrypt` — $Y = (aX + b) \bmod m^2$, $X = a^{-1}(Y - b) \bmod m^2$;
- `keys_from_pairs` — кандидати (a, b) з системи для пари зіставлень $X^* \to Y^*$, $X^{**} \to Y^{**}$;
- `is_meaningful` — автоматичний розпізнавач російської мови.

Результати друкуються в консоль і зберігаються в `results.txt`, розшифрований текст — у `decrypted_v4.txt`.

Хід роботи

1. П’ять найчастіших біграм шифртексту

Біграма	Y	Кількість	Частка
еш	179	67	0.0229
еы	182	49	0.0168
шя	774	47	0.0161
ск	537	47	0.0161
до	138	46	0.0157

2. Перебір зіставлень і кандидати на ключ

Для кожної впорядкованої пари різних біграм мови (X*, X**) з п’яти найчастіших і кожної впорядкованої пари різних біграм шифртексту (Y*, Y**) розв’язується система

$$Y^* \equiv aX^* + b,\ Y^{**} \equiv aX^{**} + b \pmod{m^2},$$

звідки $a(X^* - X^{**}) \equiv Y^* - Y^{**} \pmod{m^2}$ і $b = (Y^* - aX^*) \bmod m^2$. Залишаються лише a, взаємно прості з m, — інакше розшифрування неоднозначне.

- Усього систем: $20 \times 20 = 400$.
- У 360 системах $\gcd(X^* - X^{**}, 961) = 1$ — рівно один розв’язок.
- У 40 системах (пара «но», «то»: $572 - 417 = 155 = 5 \cdot 31$) gcd = 31, а права частина не ділиться на 31 — розв’язків немає.
- Після злиття однакових ключів отримано **175 різних кандидатів** (a, b).

3. Автоматичний розпізнавач російської мови

Обрано критерій частот частих і рідкісних літер (два перші критерії з методичних вказівок, застосовані разом). Текст вважається змістовним, якщо

- частка літер «о, а, е» ≥ 0.20 і
- частка літер «ф, щ, ь» ≤ 0.05.

Обґрунтування. У корпусі з першого практикуму частка «о, а, е» дорівнює 0.286, а «ф, щ, ь» — 0.024. Неправильний ключ дає по суті випадкову перестановку біграм, тому кожна літера трапляється з частотою близько 1/31, і обидві частки $\approx 3/31 \approx 0.097$. Пороги стоять приблизно посередині між цими значеннями, тож на тексті у кілька тисяч літер випадкові коливання не перекидають результат. Критерій рахує лише частоти окремих літер, тому не залежить від того, як текст розбито на біграми, і не потребує додаткових таблиць.

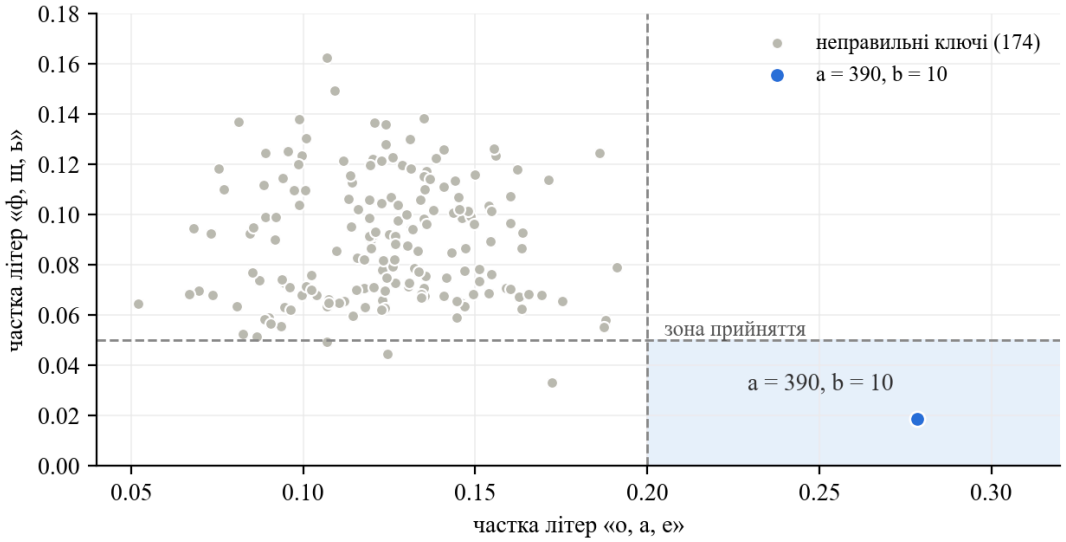


Рисунок 1: Розпізнавач на всіх 175 кандидатах: прийнято лише ключ a = 390, b = 10

Для 174 неправильних ключів частка «о, а, е» лежить у межах 0.052–0.191, а «ф, щ, ь» — 0.033–0.162. Окремо жодна умова не є абсолютно надійною (у кількох кандидатів рідкісних літер менше 0.05), але одночасно обидві виконує лише один кандидат.

4. Результат

Ключ: a = 390, b = 10 (a^{-1} mod 961 = 515). Його дало зіставлення «ст» → «еш», «то» → «до». Для розшифрованого тексту частка «о, а, е» = 0.279, «ф, щ, ь» = 0.019; найчастіші біграми — ст, ен, ни, на, то. Перевірка: повторне шифрування знайденим ключем дає вихідний шифртекст.

Шифрований текст (початок, повністю — у `ciphertext_v4.txt`):

щжуяжущпккфшчфбждоцпюдйсвжбэдуэыйэдцмодпмурзфбряцкмдыйдосштц
мижбчфипмугфбзчшохдодвзбряцкмдбэдцхзнощкяоэоюэтцюзныертзилгф
оцбчполфмэдцщкйкшйэысйрэйкчозычфждьмйшотдотзьоюйсщзоюдууюзсш
шстзрэыосяфоешыеныв…

Розшифрований текст (початок, повністю — у `decrypted_v4.txt`); це уривок зі статті З. Фрейда «Достоевский и отцеубийство»:

еслиправдачтодостоевскийвсибиринебылподверженприпадкамтоэтол
ишьподтверждаетточтоегоприпадкибылиегокаройонболеевнихненужд
алсякогдабылкараеминымобразомнодоказатьэтоневозможнокорееэт
ойнеобходимостьювнаказаниидляпсихическойэкономиидостоевского
обясняетсяточтоонпрошелнесломленнымчерезэтигодыбедствийиуниж
енийосуждение…

Труднощі та шляхи їх розв'язання

- **Порядок літер в алфавіті.** У шифртекстах практикуму «ь» стоїть перед «ы» (…шщьыэюя), а не за абеткою. З іншим порядком числа біграм зсуваються, і ключ знайти не вдається; після виправлення алфавіту текст розшифровується повністю.
- **Відмінність частот біграм у корпусі.** Корпус з першого практикуму дав трохи інший топ-5 («он», «не» замість «но», «ен»). Оскільки в перебір беруться всі пари з п'яти, а правильний ключ дала пара «ст», «то», що є в обох списках, це не вплинуло на результат.
- **Необоротне a.** Порівняння з $\gcd(X^* - X^{**}, m^2) > 1$ обробляються окремо: функція повертає всі розв'язки або порожній список, а кандидати з a, кратним 31, відкидаються.

Відповіді на контрольні питання

1. Які статистичні властивості шифртексту були використані під час формування кандидатів на ключ? Частоти біграм без перетину. Афінна підстановка взаємно однозначно переводить біграму в біграму, тому частоти зберігаються, і найчастіші біграми шифртексту (еш, еы, шя, ск, до) мають відповідати найчастішим біграмам мови (ст, но, то, на, ен).

2. Чому не кожне зіставлення частих біграм відкритого тексту та шифртексту приводить до допустимого ключа? По-перше, порівняння $a(X^* - X^{**}) \equiv Y^* - Y^{**} \pmod{961}$ може не мати розв'язків: для пари «но», «то» різниця 155 ділиться на 31, а права частина — ні (40 систем з 400). По-друге, навіть знайдене a мусить бути взаємно простим з 31, інакше його не можна обернути. По-третє, більшість розв'язків формально допустимі, але відповідають хибному зіставленню і дають безглуздий текст.

3. Чи виникали під час криптоаналізу випадки, коли одне зіставлення біграм давало декілька кандидатів на ключ? Як такі кандидати оброблялися? Для нашого варіанта — ні: в усіх 40 системах з $\gcd = 31$ права частина не ділилася на 31, тож вони не мали розв'язків. Програма на такий випадок розрахована: `solve_linear` повертає всі d розв'язків x_0, $x_0 + n_1$, …, $x_0 + (d-1)n_1$, і кожен з них перевіряється розпізнавачем як окремий кандидат.

4. За якими ознаками серед отриманих кандидатів було визначено правильний ключ? Розшифрування ключем (390, 10) — єдине, що пройшло розпізнавач: частки частих і рідкісних літер близькі до мовних. Текст читається без помилок на всій довжині, найчастіші біграми розшифрування (ст, ен, ни, на, то) збігаються з мовними, а повторне шифрування дає вихідний шифртекст.

5. Який критерій автоматичного розпізнавання осмисленого тексту було використано? Чому було обрано саме його? Комбінація критеріїв частих («о, а, е» ≥ 0.20) і рідкісних («ф, щ, ь» ≤ 0.05) літер. Він простий, не залежить від розбиття

на біграми, а різниця між мовою (0.286 і 0.024) та випадковим текстом (≈ 0.097 і 0.097) настільки велика, що на тексті у 5846 літер похибка неможлива.

6. Як поводився обраний критерій для правильного відкритого тексту та для результатів розшифрування неправильними ключами? Для правильного ключа: 0.279 і 0.019 — майже як у корпусі. Для 174 неправильних: частих літер 0.052–0.191 (жоден не досяг 0.20), рідкісних 0.033–0.162. Правильний кандидат відокремлений від решти з великим запасом (див. рисунок).

Висновки

Афінна біграмна підстановка зберігає частоти біграм мови, тому зіставлення п’яти найчастіших біграм шифртексту й мови та розв’язання лінійних порівнянь за модулем m^2 дає невелику множину кандидатів (175 для нашого варіанта). Простий розпізнавач за частотами частих і рідкісних літер автоматично відкинув усі неправильні ключі і залишив один — $a = 390$, $b = 10$, яким розшифровано змістовний текст. Ключовим технічним моментом було коректне розв’язання порівнянь з $\gcd > 1$ та правильний порядок літер в алфавіті.